

1. 介绍

循环神经网络（Recurrent Neural Networks, RNNs），特别是长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环神经网络（Gated Recurrent Neural Networks, GRU），已经在序列建模和转换问题（如自然语言处理和机器翻译）中成为了状态引领的方法。自那以后，已经持续不断地在循环语言模型和编码器-解码器架构的边界上推动研究。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间的步长上，从而生成一个隐藏状态序列 h_t ，作为前一个隐藏状态 h_{t-1} 和输入序列的位置 t 的函数。

并行化在训练数据中并不保证连续性，这在长序列长度下变得非常重要，因为内存限制会阻止跨示例的批量处理。最近的工作通过分解技巧和条件实现显著的计算效率改进。

计算，同时提高在后者中的模型性能 Attention 机制已经成为各种任务中序列建模和传输模型的不可或缺的部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离 In all but a few cases, such attention mechanisms are used in conjunction with a recurrent network 在我们的工作中，我们提出了 Transformer 模型架构，摒弃了循环结构，完全依赖注意力机制来建立输入和输出之间的全局依赖关系。Transformer 允许实现显著的并行化，在仅用 8 个 P100 GPU 进行训练的情况下，可以达到与现有技术的翻译质量的新水平。

2 背景

减少序列计算的目标也是扩展神经网络 GPU（ByteNet 和 ConvS2S）的基础，它们都使用卷积神经网络作为基本构建模块，为输入和输出位置计算隐藏表示并行计算。在这些模型中，从两个任意输入或输出位置将信号进行关联所需操作的数量在位置之间随距离线性增加，对于 ConvS2S 模型。

对 ByteNet 进行 logarithmic 变换，这使得在远离的 positions 之间学习依赖更加困难。在 Transformer 模型中，这可以减少到一个常数。

操作次数，尽管由于平均注意力的加权位置而降低了有效分辨率，但我们可以抵消这种影响

3.2节中描述的多头注意力