

1. 介绍

循环神经网络（Recurrent Neural Networks, RNNs），特别是长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环神经网络（Gated Recurrent Neural Networks, GRU），已经被证明是序列建模和转换问题的最佳方法，例如自然语言处理（Language Modeling）和机器翻译等任务。自那时以来，已经持续不断地在循环语言模型和编码器-解码器架构的边界上推动创新。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间的步长上，从而生成一个隐藏状态序列 h_t ，作为前一个隐藏状态 h_{t-1} 和输入序列 t 的函数。

并行 nature 排除了在训练实例中并行化的可能性，这在长序列长度下变得至关重要，因为内存限制会阻止跨示例的批量。最近的工作通过因子分解技巧和条件实现显著提高了计算效率。

计算，同时提高在后者中的模型性能 Attention 机制已经成为各种任务中序列建模和传输模型的不可或缺的部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离 In all but a few cases, such attention mechanisms are used in conjunction with a recurrent network In this work, we propose the Transformer, a model architecture that avoids recurrence and instead relies entirely on an attention mechanism to draw global dependencies between input and output. The Transformer allows for significantly more parallelization and can reach a new state of the art in translation quality after being trained for as little as twelve hours on eight P100 GPUs.

2 背景

减少序列计算的目标也是扩展神经网络GPU的基础，ByteNet和ConvS2S，它们都使用卷积神经网络作为基本构建模块，并计算所有输入和输出位置的隐藏表示并行在这些模型中，从两个任意输入或输出位置相关联的操作用于增加距离，线性地对于ConvS2S模型。

对ByteNet进行logarithmic推理。这使得在远离彼此位置的学习依赖时变得更加困难。在Transformer中，这已经被减少为常数。

操作次数，尽管由于平均注意力的加权位置而导致的有效分辨率降低，但我们仍能克服这种影响。

3.2 中的多头注意力