

1. 介绍

循环神经网络（Recurrent Neural Networks, RNNs），特别是长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环神经网络（Gated Recurrent Neural Networks, GRU），已经在序列建模和转换问题（如自然语言处理和机器翻译）中取得了重大的突破。自那时以来，已经持续不断地在循环语言模型和编码器-解码器架构的边界上推动研究。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间的步长上，从而生成一个隐藏状态 h_t ，作为前一个隐藏状态 h_{t-1} 和输入序列的位置 t 的函数。

并行 nature 排除了在训练例子中并行化的可能性。这在较长的序列长度下变得至关重要，因为内存限制会限制在示例之间进行批处理。最近的工作通过因子分解技巧和条件实现显著提高了计算效率。

计算，同时提高模型性能在后者情况下，序列计算的基本约束仍然是注意机制已成为各种任务中引人注目的序列建模和传输模型的关键组成部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离对于序列中的大部分情况来说，尽管如此。这些注意机制通常与循环网络一起使用我们的工作提出了一种名为Transformer的模型架构，该架构不使用循环结构，而是完全依赖于注意力机制来绘制输入和输出之间的全局依赖关系。Transformer允许实现显著的并行化，可以在训练时间只需12小时的情况下达到目前最佳翻译质量的新状态。

2背景

减少序列计算的目标也是扩展神经网络GPU（ByteNet和ConvS2S）的基础，它们都使用卷积神经网络作为基本构建模块，对输入和输出位置进行并行计算，实现隐藏表示。在这些模型中，从两个任意输入或输出位置将信号进行关联所需的操作数量在位置之间随距离线性增加，对于ConvS2S模型。

对ByteNet进行logarithmic变换。这使得在远离的 positions之间学习依赖变得更加困难。在Transformer中，这被减少为常数。

操作次数，尽管由于平均注意力的加权位置而降低了有效分辨率，但我们可以抵消这种影响。

3.2 中的多头注意力