

MLink: 联合多个黑盒模型进行协作多模型推理

木元, 兰张*, 洋洋李

University of Science and Technology of China
 ym0813@mail.ustc.edu.cn zhanglan@ustc.edu.cn
 xiangyangli@ustc.edu.cn

Abstra

模型推理的效率对于实际的机器学习应用至关重要, 尤其是在延迟敏感的任务和资源有限的设备上。一个典型的困境是: 为了提供复杂的智能服务 (例如智慧城市), 我们需要多个机器学习模型的推理结果, 但是成本效率是一个问题。预算 (例如GPU内存) 不足以运行所有这些模型。在本工作中, 我们研究了黑盒机器学习模型之间的内在关系, 并提出了一种新的学习任务: 模型链接。模型链接旨在通过学习映射 (称为模型链接) 来弥合不同黑盒模型之间的知识。在他们的输出空间之间根据模型链接, 我们开发了一种调度算法, 命名为 MLink。通过模型链接, MLink可以在成本预算下提高获得推理结果的准确性。我们对具有7个不同ML模型和两个真实世界视频的多模态数据集进行了MLink评估

analytics systems with six ML models and 3,264 hours of video Experimental results show that our proposed model links can be effectively built among various black-box models Under the budget of GPU memory, MLink can save 667%多模型的推理任务越来越普遍, 例如智能零售 (Bentley et al. 2018) 和自动驾驶 (Feng et al. 2020) 等。这些任务通常需要将来自多个模态的数据 (例如语音、图像、视频等) 结合起来进行分析和决策。为了应对这些工作负载, 研究人员已经提出了一系列多模态模型, 这些模型可以将来自不同模态的数据结合起来, 并从中提取有用的信息。这些模型通常使用深度学习技术来实现, 例如卷积神经网络 (CNN)、循环神经网络 (RNN) 和注意力机制 (Attention) 等。2020), 除了模型的准确性, 推理阶段的成本可能会成为服务质量的瓶颈。尤其是在延迟敏感的任务和资源有限的设备上为了实现在成本效率, 现有的工作探索了各种资源性能权衡的方法多任务学习和压缩 (He Zhou and Ren 2020) Thiele et al. 2021; Sanh, Wolf, and Ruder 2019; Crawshaw 2020; Zhang and Yang 2021) can reduce the computing overheads by sharing neurons among different tasks; Model compression (Hinton, Vinyals, and Dean 2015; Liu et al 2018; Goldfeld and Carbin 2019; Yang et al 2020; Yang et al 2021) can reduce the memory footprint of neural networks; and distillation (Buciluău et al 2016; Hinton et al 2015; Kim et al 2016; Romero et al 2014; Zhang et al 2019) can improve the performance of neural networks by training them on smaller datasets.

Bai et al. (2020) and Blum et al. (2020) techniques aim to eliminate parameters and connections that are not relevant to the accuracy of inference. Guo et al. (2018) and Ning, Guan, and Shen (2019) proposed inference reusing approaches to avoid redundant computations. Li et al. (2020) proposed source filtering methods to transmit only necessary input data to the backend ML models. Jiang et al. (2018) proposed adaptive configuration methods, and Yuan et al. (2020) proposed multi-model scheduling methods. 2020a) 提出了让推理工作负载适应输入内容动态变化的方法。我们将其总结为回答一个有趣的问题: 如何在不执行机器学习模型精确执行的情况下尽可能准确地获得推理结果? 从这个角度来看, 多任务学习和模型压缩通过剪枝原始模型来生成更轻量级的模型, 用于相同的推理任务。推理重用和源过滤技术通过分析输入之间的相关性, 将先前的推理结果作为预测结果重新使用。根据观察到的情况, 对于一些输入数据, 昂贵和便宜的模型的准确性相似。自适应配置分析输入动态, 并通过执行便宜的模型来预测昂贵模型的推理结果。自适应多模型调度预测执行的模型不必要的推理结果。我们从一个新颖的角度来解决这个问题: 将黑盒模型的输出作为提示信息。我们受到启发, 认为即使在输入模态、学习任务、架构等方面不同的ML模型, 也可以相互分享知识, 因为ML模型倾向于学习到通用的模式。overlearning指的是在训练过程中学习更多的知识, 以提高模型的泛化能力。而不同模型的输出之间可能存在语义相关性, 这可以通过使用语义表示学习算法来实现。如果我们能够有效地将不同模型之间的知识进行桥接, 那么我们就可以根据已执行模型的输出来直接预测剩余模型的推断结果。如果这个预测的成本很低, 那么这种方法有望提高所有模型在有限计算资源下的推断结果的准确性。成本预算与原始工作流相比有什么不同? 为了实现这一愿望, 需要解决两个主要挑战: (1) 如何在黑盒子和高度不同的机器学习模型之间建立知识级别的链接? 实际上, 部署的机器学习模型可以有不同的架构和输入模态, 并且可以由不同的编程语言和机器学习框架开发。异构性

[illegible]

多源模型链接集成 当模型数量 k 大于等于3时，对于一个目标模型 j ，可能会有来自不同源的多个模型链接。设 $A \subseteq F$ 为模型子集集合，那么对于 A 中的所有 $\hat{f} \in A$, g_{ij} 。由执行预测任务 J 的推断输出是：接下来要解决的问题是，如何确定最终预测？从集成学习的角度来看， $\{g_{ij} | \hat{f}_i \in A\}$ 构成一个多专家模型（Yuksel, Wil-son, and Gader 2012），它可以利用多任务和 multimodal 表示更好地进行预测（Baltrušaitis, Huja, and Morency 2018;《张杨2021》）。我们定义 h_A, j 为 A 到 j 的 ensemble 模型链接 h_A, j 是 g_{ij} 预测的集合，其中 f_i 表示第 i 个样本的标签如果 A 只含有一个元素 $\hat{f}$ ，那么 $h_A, j = g_{ij}$ 。 $\hat{f}$ 多模态推理预算约束模型 这个模型可以用来实现多模态推理任务的资源性权衡用 $c(\cdot)$ 表示运行一个函数的成本，比如GPU内存或推理时间对于资源有限的设备（例如智能手表和移动电话）以及延迟敏感的任务（例如实时视频分析和音频助手），总成本有一定的限制。我们定义 B 为成本预算，并旨在在预算范围内最大化推理准确率。令 $p(h_A, j)$ 表示性能指标在多模态模型链接中，目标模型的任务取决于模型的范围。我们假设 p 的范围被归一化到 $[0, 1]$ 。例如，对于分类任务，性能指标可以是准确性，而对于检测任务，性能指标可以是边界框 IoU。遵循先前优化推理效率的努力(Li et al. 2020; Yuan et al. 2020a)提出了了一种新的性能度量方法，用于衡量所获得结果与精确推断输出之间的一致性，而不是真实输出。多模态预算约束下的推理问题被形式化为：

$$\max_{A \subseteq F} \left(\frac{|F|}{|A| + 1} \sum_{j \in J(A)} p(h_A, j) \right) \quad (1)$$

s.t. $\hat{f} \in A$ 属于 ac $\hat{f} \in ac(h_A, j) \leq B$

我不太明白 $\hat{f} \in ac(h_A, j) \leq B$

白您意 $\hat{f} \in ac(h_A, j) \leq B$

在成本预算下，我们面临的问题是在通过选择执行的激活子集 A 来最大化所有模型 F 的平均性能。为了便于描述，我们定义目标函数为输出准确率。激活模型进行精确推理，因此其性能分析分为未激活的模型仅参与构建模型链接，而在推理阶段不会执行；相反，它们由激活的模型通过 ensemble 模型链接预测激活模型的费用是执行精确的推理，而预测模型的费用是从运行模型链接中获得的。因此，模型链接应按既定权重及数量级，以减少成本。同时保持多模型推理工作质量。

常，对齐输入空间存在于多模态场景的上下文中g, multi-modality event detection (Elho- seiny et al 2016) and visual speech synthesis (Baltru'saitis, Ahuja, and Morency 2018)在实践中，时间同步可以轻松地将输入对齐 for many applications。此外，诸如 Black, Ellis 和 Rosin (2002) 提出的多视图视频空间对齐和音频- 视频同步等方法也可以用于对齐 mantic alignment (Wang, Fang, and Zhao 2020) can be adopted for specific scenarios We define model linking as a function $g_{ij} : Y_i \rightarrow Y_j$, 即从源模型 f_i 的输出空间到目标模型 Y_j 的映射 f_j 's然后复合函数 $g_{ij} \circ f_i : X_i$ 可以执行 f_j 的推理计算。相应地, g_{ji} 将 f_i 的知识链接到 $g_{ji} \circ f_j$

黑盒模型链接

在这个部分，我们讨论了将黑盒模型链接起来的动机，并提出了模型链接的理论分析、架构设计、集成和训练方法

激励学习

在训练不同任务的 ML 模型时，理想的模型学习的表示应该是独立的且相互独立的 (Hjelm 等人, 2019 年)。换句话说，每个模型只学习其目标任务的语义，而不会受到其他任务的影响。然而，由于数据和模型的复杂性不匹配，实际情况下很难实现这一理想。机器学习过程容易出现“过拟合” (Song and Shmatikov 2020)，这意味着无意的语义被编码在学习的表示中。此外，不同任务和不同模型的输出之间存在语义关联，不同的模型可能会关注相同的内容，例如图像中的相同区域。example, in Fig 1a, based on G-CAM (Selvaraju et al 2020年我们绘制了YOLO-V3 (Redmon and Farhadi 2018)对象检测器和 ResNet50 (He et al 2016)的注意力热图scene classifier on the same images, and their attention areas have much overlap We experimented on the correlation between the overlap ratio of attention heatmaps and the performance of model linking For example, from the scene classification model to the object detection model, as shown in Fig 1b, the模型链接的准确性显然与重叠比((Mapsource $\wedge$ Maptarget)/Maptarget)有关。在一定程度上，模型学习到的关联链接与语义注意力相耦合。这种原理学习我构建使模型间的耦合输出来消除模型间耦合的冗余输入。通过调用高维特征空间的映射与转移 (T)品用表示可以用于预测其他不同的任务。然而，在实际应用中，我们经常需要处理部署的模型，这些模型只提供黑盒推理API。与中间表示相比，下游的黑盒输出在通用学习任务中具有较弱的表示能力。但是最近的工作 (Yuan et al. 2021) 表明，通过将黑盒输出转换为中间表示，可以提高模型的泛化能力。2020a)研究表明，对于相同的输入或对齐的输入，执行的模型的输出对于安排未执行的模型是非常有效的提示。这一洞察是，多个任务之间具有相同输入的黑盒输出之间的相关性比中间特征更明确，甚至更强。我们的实验表明结果表明，在使用相同量的训练数据的情况下，黑盒模型链接的准确率高于知识蒸馏方法 (见图2) 和多任务学习方法 (见表4)。考虑到更好的实用性以及满意的准确率，我们选择黑盒输出而不是中间表示来进行链接ML models




图1：不同模型之间的语义相关性

样本复杂度分析

f属于F表示任务特定参数，h表示跨任务共享参数。已经证明，当h的训练数据充足时，仅需要C(F)样本复杂度 (Tripuraneni, Jordan, and Jin 2020)，就可以在新任务上达到有界的预测误差。is the complexity of a hypothesis family Learning a model link $g_{ij} \in G$ from source model f_i in F_i , the target f_j belongs to F_j , and the compound learning model $g_{ij} \circ f_i$ represents the process of combining F_i and f_j to form g_{ij} .轻量级模型链接设计可以使C(G) < C(F_j)成立。因此，应用上述结果，模型链接可以显著降低学习目标模型的样本复杂度，与从头学习目标模型的C(F_j)复杂度相比。这个结果也被我们的实验所证实。模型链接模型可以通很少量的训练样本 (例如模型链接了黑盒模型的输出空间，因此输出格式决定了架构。我们把输出格式分为固定长度向量和变长序列。这两种输出可以涵盖大多数机器学习模型。我们提出了四种基于最佳实践的模型链接架构相似学习任务的Vec-to-Vec模型：该模型将向量输出源映射到向量输出目标。我们使用ReLU激活的多层感知器 (MLP) 作为Vec-to-Vec模型的链接Seq-to-Vec模型：该模型将序列输出源映射到向量输出目标。我们首先使用一个嵌入层，它将序列映射到一个固定大小的嵌入向量。然后我们使用一个LSTM层 (Hochreiter and Schmidhuber 1997) 接着是一个MLP来生成向量输出。Vec-to-Seq：模型链接从一个向量输出源到一个序列输出目标。我们采用编码器-解码器框架，其中MLP作为编码器，解码器由嵌入层、LSTM层、注意力层 (Bahdanau, Cho和Bengio 2015) 和全连接层组成，按顺序为Seq-to-Seq：模型链接从一个输出为序列的源映射到一个输出为序列的目标。我们采用序列到序列框架 (Sutskever, Vinyals, and Le 2014)，其中嵌入层和LSTM层作为编码器，解码器与vec-to-seq模型中的解码器相同

输出激活函数是由目标模型的学习任务决定的，对于单标签分类，使用softmax，对于多标签分类和序列预测，使用sigmoid线性激活函数可用于回归和定位任务。在我们的实现中，默认的隐藏单元数量是输出维度的两倍，这在有效性与效率之间实现了良好的权衡。

多源链接集合模型有潜力提高预测性能(Shen, He, and Xue 2019)，因为跨任务和跨模态表示能力是有益的。对于目标模型 f_j ，给定源集 A ，我们乘以 g_{ij} 的输出 trainable weights, where $f_i \in A$ 根据 f_j 的学习任务，使用 $h_{A,j}$ 学习到的权重来组合模型链接，来自任何子源集 $i \in A$, $A' \subset A$

在经典知识蒸馏 (Hinton、Vinyals和Dean 2015) 中，训练“学生”模型时，软标签监督比硬标签监督更好，因为“教师”模型的输出可以为不同类之间的关系增加硬标签空间。我们的实验结果表明，在提出的模型中，这种经验仍然适用。为了训练模型链接和ensemble模型，我们收集了 n 个推断结果 $\{y_j\}_{j=1}^n$ $n=1$ from k models on the same or aligned inputs Given f_i, f_j as the source and the target, respectively, the objective of training the model link g_{ij} is $\min_{g_{ij}} L_j(g_{ij}(y_i))$ and $y_l(j)$ are the input and output of the j -th layer of the target model f_j , respectively. The loss function L_j depends on the learning task of the target model f_j . 给定源集合 A 和目标集合 f_j ，训练联合模型 $h_{A,j}$ 的目标是：对于任意的 y_l 和 $f_i \in A$ ，最小化损失函数 $\Delta(A, f_i) = F(A \cup \{f_i\}) - F(A)$ 。假设将一个源模型链接到集成模型中不会降低性能，则： $p(A \cup \{f_i\}) \geq p(A)$ 根据周(2012)的实证研究， $p(A, f_j)$ 是真实的那么 $\Delta(A, f_i) \geq 0$ 在我们的实验中，我们观察到了两种典型情况：(1) 主导地位 堆栈模型的性能大约等于最佳性能源模型链接 Let $f_i^* = \arg\max_{f_i \in A} p(g_{ij})$ 定义为 f_i^* 为 A 中 g_{ij} 的最佳性能源模型链接笔记来源：在性能最优的情况下，我们观察到 $p(h(A, f_i)) \approx p(g_i^*)$ ，即(1) 最优源主导集成性能 (2) 互助 多源模型将集成优于任何单一源对于所有 $f_i \in A$, $p(h(A, f_i)) > p(g_{ij})$ ，即模型链接的来源相互辅助。在这种情况下，如果 f_j 与 A_2 中的模型协作更好，那么 f_j 为 A_2 带来的收益可能大于为 A_1 带来的收益，因为 A_1 包含 A_2 。

算法1: 协同多模态推理

输入: 模型集 F , 成本预算 B

对于任意的 $f_i, f_j \in F, i \neq j$, 训练模型链接 g_{ij}

对于每一个 f_j 属于 F , 训练一个ensemble模型 $h_{A,j}$, 其中 $A_j = F \setminus \{f_j\}$

每步耗时30分钟

4 Profiling activation probability of $f_i \in F$

贪婪地选择 A ，直到达到成本预算 B ，其中 A 是 F 中

$\arg\max_{f_i \in F \setminus A(P_i)}$ 的集合

Given incoming input x , for $f_i \in A$

如果 f_i 属于 A , 则: $y_i \leftarrow f_i(x)$

8 else: $y_i \leftarrow h_{A,i}(y_j) f_j \in A$.

我不

太明

白您

激活概率求解方程(1)是NP-hard的，并且 $(1-e^{-1})$ -近

似算法(Sviridenko 2004)需要部分枚举，并且需要

($\ln 5$)计算目标函数 优化不是一个一次性的过程，而

是在线上执行以适应推理系统的动态。因此，我们

提供了一个启发式激活概率指标，其计算只依赖于模

型链接的性能，而不是ensemble模型的性能。给定一

个模型 f_i ，激活概率可以计算为：

$$P(f_i) = \frac{1}{n} \sum_{j=1}^n P(f_i | f_j) = \frac{1}{n} \sum_{j=1}^n \frac{p(f_i, f_j)}{p(f_j)}$$
其中 $P(f_i | f_j)$ 表示第 i

个源模型在模型 f_j 下的概率， $P(f_j)$ 表示第 j 个激活

状态在模型 f_j 下的概率， $p(f_i, f_j)$ 表示第 i 个激活状态的概

率。联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

联合概率 $p(f_i, f_j)$ 表示模型 f_i 和模型 f_j 同时被激活的概率。

任务: ClassML Model 输入: Modality 输出: FormatMetric
 Single-Label Classification Gender Classification (Kumar 2021) Audio2-D Softmax Labels Acc.
 多标签分类 (Tran et al. 2015) 视频12-D Sigmoid标签 mAP
 LocalisationFace Detection (Serengil and Ozpinar 2020)Image4-D Bounding BoxIoUPerson Detection
 (Redmon and Farhadi 2018)Image
 RegressionAge Prediction (Levi and Hassner 2015)Image1-D ScalarMAE
 Sequence GenerationImage Captioning (Wang 2021)ImageVariable-Length TextWERSpeech Recognition
 (Mozilla 2021)Audio

Table 1: 洛杉矶2数据集上使用的机器学习模型总结

我们基于TensorFlow 20 (TensorFlow 2021) 在Python中实现了我们的设计, 作为推理系统的插件式中间件1我们测试了使用TensorFlow (TensorFlow 2021)、PyTorch (PyTorch 2021) 和MindSpore (MindSpore 2021) 编写的程序, 只需要几十行代码的修改, 就可以使用MLink, 这表明MLink的易用性。我们对我们的设计在多模态数据集和两个实际的视频分析系统上进行了评估多模态数据和机器学习模型 我们使用了好莱坞2视频数据集 (Marszalek, Laptev, and Schmid 2009) 来获得多模态模型的对齐输入。我们选择了每段视频的第30帧, 并从中提取了音频数据。我们部署了七种预先训练的机器学习模型, 涵盖了五类学习任务: 单标签和多标签分类、回归和生成。多标签分类, 对象定位, 回归和序列生成是不同的任务, 它们有不同的模型架构, 输入模式和输出格式。为了评估模型链接的性能, 我们使用了特定任务的指标, 包括准确性, 平均平均精度 (mAP), 边界框交并比 (IoU) 和平均绝对误差 (MAE) 和 (WER)Table 1总结了这些ML模型在智能建筑和城市交通监测系统中的应用我们对MLink在两个实际的视频分析系统上进行了评估1. 智能建筑 支持包括自动空调和照明的应用程序, 以及异常事件监控这三个模型分别是: 监督学习、房地产安全和财产安全 OpenPose (Cao et al 2019)-基于的人数计数, ResNet50 (He et al 2016)-基于的动作分类 (Olafenwa 2021a), YOLOV3 (Redmon and Farhadi 2018)-基于的对象计数 我们收集了两天 (一个工作日和一个周末) 的视频帧, 来自所有58个摄像头 (每分钟1帧) 我们使用边缘检测算法来检测视频中的物体, 并使用这些检测结果来计算物体的数量一台服务器, 配备一块NVIDIA 2080Ti显卡在城市规模的视频分析平台上, 部署了三个AI模型用于交通监测: 基于Open-Pose的人员计数、基于ResNet50的交通状况分类 (Olafenwa 2021b) 和基于YOLOV3的车辆计数。我们在路口选择了10台摄像机, 连续采集了2天 (一个工作日和一个周末) 的帧 (每秒1帧) 我们使用了5台服务器, 每台服务器配备4个NVIDIA T4 GPU

我们介绍了一种简单的独立推断方法和三种强大的替代资源性能权衡方法作为基线 (1) 独立推断: 独立运行模型 (2) MTL: 我们采用了一种多任务学习架构 (Crawshaw 2020), 该架构包括一个全局特征提取器, 由所有任务共享, 以及针对每个任务的输出分支。我们还采用了 (3) 模型融合: 将多个模型的输出融合在一起, 以获得更好的性能。使用ResNet50 (He et al, 2016) 实现特征提取器和全连接层, 用于特定任务输出。我们使用ImageNet (Deng et al, 2009) 预训练的ResNet50特征提取器, 并连接三个输出分支用于人数计数, action/traffic classification, and object/vehicle count-任务是基于智能建筑和交通监测测试床的MTL模型训练。这些模型是在相应的模型的精确推断结果监督下训练的(3) Reducto (Li et al. 2020): 一种帧过滤方法 对于每个模型, Reducto首先计算相邻帧之间的特征差异 如果特征差异低于一个阈值, 它将过滤掉当前帧并重新使用最新的推理输出 我们测试了四种低层次的特征根据 Reducto提出的建议, 我们选择了性能最佳的方案 (4) DRIS (基于深度强化学习的调度程序) (Yuan et al. 2020a) 和多模型调度方法DRIS使用深度强化学习 (Crawshaw 2020) 来调度任务 我们使用了一个模型调度器来执行模型的输出 为了测试不同大小的训练数据对模型链接性能的影响, 我们进一步随机抽取了四个不同的训练数据集, 每个数据集的大小分别为: 200、400、600、800个视频剪辑。我们使用了10%、20%、50%和100%的训练数据比例, 相对于总数据集。我们使用RMSprop (Tieleman and Hinton 2012) 优化器和相同的超参数 (学习率为0.001, 训练周期为100, 批量大小为32)。为了公平比较, 我们采用了知识蒸馏Hinton, Vinyals, and Dean在2015年提出了一种方法, 用于一些目标模型 (Action, Age, Gender) 中, 其中学生模型具有两个卷积层我们重复了三次实验, 并报告了性能的平均值和标准差。如图2所示, 使用所有训练数据, Caption-to-Action模型链接可以达到317% mAP。而模型链接之间的两个检测模型, Face-to-Person和Person-to-Face模型链接, 可以达到59% 和 32% IoU 分别, 即使有非常有限的训练样本, 一些模型链接也能达到很高的性能




Figure 2: IoU scores of model links targeted to the Person model and the Pearson correlations.

Table 2: IoU scores of model links targeted to the Person model and the Pearson correlations.

performance The model link from Face to Gender achieves 921% accuracy And for model links Gender-to-Age model achieves 30 MAE Compared with student models trained via knowledge distillation on the target models, model links achieves higher prediction performance, especially when the amount of training data is small But for speech I don't understand your meaning, please re-enter with the highest confidence for the localization model, we checked the bounding box whether it is empty, and set it as a label, set its value to 0 or 1. We use the regression score as a label, and skip the two sequence generation models. Table 2 shows the results of the target model link, we can see that the model link performance is positively correlated with the Pearson correlation coefficient. Table 3 shows the results of the ensemble model link in five target models.




Figure 3: MLink service latency and memory usage on various devices.

所有的训练样本（48%的比例）模型链接组合优于每一个单独的源模型。我们可以看到有两种典型的案例：主导和互助对于Action, Face, Person目标, Caption, Person, Face来源分别主导了整个集合的表现。但是对于Age和Gender目标, 源模型相互辅助并通过集合实现性能提升。

我们对智能建筑系统中的58个摄像头和城市交通监测平台上10个摄像头的48小时视频进行了MLink测试。我们利用数据的前10%进行模型链接和ensemble的训练。我们设置时间长度为一个小时使用初始1%数据进行特征激活概率建模。对于计数模型, 输出精度通过检查预测数的绝对误差是否小于0.5来计算。每个机器学习模型的时间成本是通过训练数据的离线轮廓平均推理时间计算的。在智能建筑系统中, 动作/人物/物体模型每帧耗时30/44/60毫秒。在交通监控系统中, 交通/人物/车辆模型每帧耗时55/66/70毫秒。每个ML模型的GPU内存成本是高峰年龄: 46 GB 用于个人计数, 15 GB 用于动作/交通分类, 37 GB 用于对象/车辆计数。我们设定预算B为最大GPU内存分配给ML模型, 以评估MLink如何提高多模型推理的资源效率。我们把每个ML模型的输出作为输入准确率相等并报告他们的平均输出准确率在GPU内存预算下, 基本的“Standalone”仅选择平均耗时最短的模型。我们重复了调度实验三次, 并在表4中报告了结果。由于标准偏差较小(< 0.1), 为了简单起见, 我们没有进行呈现。在两个系统中MLink在输出精度方面优于替代方案。与“Standalone”相比, 在智能建筑系统中, MLink节省了667%的推理执行时间MLink在保持941%输出精度的同时, 实现了对四种不同设备（一台云服务器、一台边缘服务器、一台笔记本电脑和一台移动电话）的部署, 并对其延迟和内存占用进行了测试。如图3所示, MLink只会引入微小的额外开销

Target \ Source Action Age Caption Face Gender Person Speech Ensemble
 Action mAP(%)12.8(±1.3)29.7(±1.4)10.1(±1.3)9.3(±0.3)9.9(±1.2)8.5(±3.1)30.8(±1.1)Face
 IoU(%)11(±1.3)11.2(±1.0)0 (±0)-10.3(±0.9)31.9(±0.3)0 (±0)32.2(±0.2)Person
 IoU(%)39.4(±0.1)38.9(±0.1)0(±0)58.5(±1.3)39.0(±0.1)0(±0)59.2(±1.2)
 Age MAE3.04(±0.01)3.02(±0.01)3.07(±0.02)3.0(±0.01)3.03(±0.01)3.0(±0.01)2.98(±0)Gender Acc.
 (%)92(±0.1)92.1(±0.2)92(±0.1)92.1(±0.1)-92(±0.1)92(±0.1)92.3(±0)

Table 3: 模型链接集成中的主导和相互帮助案例。列标题是源模型，行标题是目标模型。主导源的性能以粗体显示。

Method	Building (5/9GB Mem.)	City (5/9GB Mem.)
	Acc. (%)	Time (ms)
Standalone	33.3/66.730	7433.3/66.755
MTL	53.332.861	332.5DRLS45.7/81.358.7/10739.5/77.6102
188Reducto	91.8/96.945.7	/8984.1/95.364
MLink	94.1/97.939.3	/8494/97.462

表4：MLink, MTL, Reducto, DRLS和 Standalone方法在两个视频分析系统上的比较

相关工作

多任务学习和压缩一种直接优化多个独立机器学习模型的方法是多任务学习 (Sanh, Wolf和Ruder 2019; Caruana et al. 2001)。在多任务学习中，模型在多个任务上共享参数，从而减少了训练和推理的计算成本。此外，多任务学习还可以提高模型的泛化能力，因为模型可以从共享参数中学习更多的通用知识。张和杨(2021)和压缩(He, Zhou和Thiele, 2018)多任务模型可以在相同成本预算下提供比单任务模型更丰富的推理结果。但是，多任务学习方法缺乏灵活性和可扩展性，即我们需要为每个案例单独设计多任务解决方案，并且一旦设置更改，就需要重新设计。任务的变化相反，尽管不同黑盒机器学习模型之间存在参数冗余，MLink方法可以灵活扩展。实验表明，当给定少量训练数据时，模型链接的准确性更高。知识蒸馏根据最近的分类法，知识蒸馏可以分为三类：知识迁移、知识压缩和知识融合。知识迁移是将源模型的知识转移到目标模型中，从而提高目标模型的性能。知识压缩是通过减少源模型的知识量来减少目标模型的大小。知识融合是将多个源模型的知识融合在一起，从而获得更好的性能。2021年，Gou等人的研究表明，知识蒸馏有三个主要的知识来源：(1)响应(Ba和Caruana 2014; Hinton, Vinyals和Dean 2015): 教师模型的输出；(2)特征(Chen等 2021): 中间特征图；(3)关系(Passalis, Tzelepi和Tefas 2020): 关系特征映射Zhang et al. (2018) 和 Yao and Sun (2020) proposed mutual distillation, which trains an ensemble of "student" models and lets them learn from each other mutually. Ye, Lu, and Zhan (2020) proposed cross-task distillation, which trains a "student" model by a "teacher" model pre-trained for another task.Model link-我方大明白您的意思

一种基于强化学习的多模态数据标注任务调度算法，利用已执行模型的输出作为提示信息来调度剩余模型 Reducto (Li et al. 2020)通过设置相邻帧特征差异的阈值来过滤视频帧 DNNs-aware video streaming (Xie and Kim 2019; Kim et al. 2020)通过利用深度神经网络 (DNN) 的输出来优化视频流的传输Du et al.2020年提出了一种用于通信效率优化的推理精度压缩方法FoggyCache (Guo et al. 2018)利用自适应哈希输入值来重用缓存的推理结果。我们提出MLink调度程序以一种新颖且更直接的方式优化成本效率：通过已执行模型的输出预测未执行机器学习模型的推理结果

结论和讨论

在这个工作中，我们提出将黑盒机器学习模型链接起来，并提出模型链接的设计和一种协作的多模型推理算法综合评估表明黑盒模型链接的有效性以及MLink相较于其他替代方法的优越性。我们总结了以下局限性和未来工作：(1) 当源模型和目标模型之间的语义相关性较低时，模型链接的输出准确性较差当联合模型的数量非常大的时候， pairwise模型链接将变得不实用我们未来将研究如何智能地选择模型来构建模型链接 (3)。由于参数量较小，重新训练的成本很小（eG, a vec-to-vec model with 100-dimensional input and output lengths, costs 129 seconds for training 100 epochs using 1,000 samples. Therefore, a periodic retraining policy for updating MLink is feasible.我们将会研究在线学习和主动学习机制，以进一步提高MLink对输入动态的适应性并减少更感谢

这项研究得到了中国2021年国家重点研发计划的支持，以及中国2018年国家重点研发计划的支持，同时得到了中国国家自然科学基金的资助，编号分别为61822209、62132018、61932016和61932017这是中国科学技术协会-华为“基础科学基金”资助的项目，项目编号为61625205

参考

- Ba, J., and Caruana, R. 2014. Do Deep Nets Really Need to be Deep? *Advances in Neural Information Processing Systems*, 27, 2110–2118.
- Bahdanau, D., Cho, K. H., and Bengio, Y. 2015. Neural machine translation by jointly learning to align and translate. In *3rd International Conference on Learning Representations (ICLR)*, 2015.
- Banerjee, S., and Sengupta, A. 2015. Deep network compression via cross distillation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, 3203–3210.
- Bastani, F., and Shrivastava, A. 2018. Multi-modal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2): 423–443.
- Chen, R., White, B., and Lottridge, D. 2018. Understanding the long-term use of smart speaker assistants. *Proceedings of the ACM on Interactive, Mobile, and Wearable Computing Technologies*, 22(3): 1–14.
- Cao, Z., Hidalgo Martinez, G., Simon, T., Wei, S., and Sheikh, Y. A. (2019). OpenPose: Realtime Multi-Person 2DPose Estimation using Part Affinity Fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(11): 3326–3341.
- Chen, Y., and Li, C. 2019. Cross-layer distillation with semantic calibration. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, 7028–7036.
- Chen, Y., Li, C., and Li, C. 2019. arXiv preprint *Deep neural networks: A survey*. arXiv:1909.09869.
- Chen, Y., Li, C., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. 2009. Imagenet: A large-scale hierarchical imagedatabase. In *2009 IEEE Conference on computer vision and pattern recognition*, 248–255. IEEE.
- Chen, Y., Li, C., and Li, C. 2020. Surveillance via Drone: A Brief Survey. In *2020 International Conference on Information and Communication Technology, Chengdu, China*, 948–952. IEEE.
- Chen, Y., Li, C., and Li, C. (2020). Server-Driven VideoStreaming for Deep Learning Inference. In *Proceedings of the Annual conference of the ACM Special Interest Group on Data Communication on the applications, technologies, architectures, and protocols for computer communication* (pp. 557–570).
- Elhoseiny, M.; Liu, J.; Cheng, H.; Sawhney, H.; and Elgamal, A. 2016 Zero-shot event detection by multimodal distributional semantic embedding of videos In *Thirtieth AAAI Conference on Artificial Intelligence* Feng, D.; Haase-Schütz, C.; Rosenbaum, L.; Hertlein, H.; Glaeser, C.; Timm, F.; Wiesbeck, W.; and Dietmayer, K. 2020 Deep multimodal distributional semantic embeddings for zero-shot event detection multi-modal object detection and semantic segmentation for autonomous driving: Datasets, methods, and challenges *IEEE Transactions on Intelligent Transportation Systems*, 22(3): 1341–1360.
- Goldblum, M.; Fowl, L.; Feizi, S.; and Goldstein, T. 2020 Adversarially robust distillation In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, 3996–4003.
- Gou, J.; Yu, B.; Maybank, S. J.; and Tao, D. 2021 Knowledge distillation: A survey *International Journal of Computer Vision*, 1–31.
- Guo, P.; Hu, B.; Li, R.; and Hu, W. 2018 FoggyCache: Cross-device approximate computation reuse In *Proceedings of the 24th Annual International Conference on Mobile Computing and Networking*, 19–34.
- Guo, Y.; Shi, H.; Kumar, A.; Grauman, K.; Rosing, T.; and Feris, R. 2019 Spottune: Transfer learning through adaptive fine-tuning In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4805–4814.
- He, K.; Zhang, X.; Ren, S.; and Sun, J. 2016 Deep residual learning for image recognition In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 770–778.
- He, X.; Zhou, Z.; and Thiele, L. 2018 Multi-task zipping via layer-wise neuron sharing In *Proceedings of the 32nd International Conference on Neural Information Processing Systems*, 6019–6029.
- Hinton, G.; Vinyals, O.; and Dean, J. 2015 Distilling the knowledge in a neural network *arXiv preprint arXiv:1503.02531*.
- Hjelm, R. D.; Fedorov, A.; Lavoie-Marchildon, S.; Grewal, K.; Bachman, P.; Trischler, A.; and Bengio, Y. 2019年, 通过互信息估计和最大化学习深度表示。在国际学习表示会议上。
- Hochreiter, S.; and Schmidhuber, J. 1997年, 长短期记忆。神经计算, 9(8): 1735–1780.
- Jiang, J.; Ananthanarayanan, G.; Bodik, P.; Sen, S.; and Strica, I. 2018 Chameleon: Scalable Adaptation of Video Analytics In *Proceedings of the 2018 Conference of the ACM Special Interest Group on Data Communication*, 253–266.
- Kumar, A. 2021 PyGender-Voice <https://github.com/abhijeet3922/PyGender-Voice> Accessed: 2021-08-01.
- Levi, G.; and Hassner, T. 2015 Age and gender classification using convolutional neural networks In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 3634–3642.
- 李洋, 帕德南, 赵鹏, 王亚伟, 徐贵华和內特拉维利, 2020 Reducto: On-Camera Filtering for

Resource-Efficient Real-Time Video Analytics In Proceed- ings of the Annual conference of the ACM Special Interest Group on Data Communication on the applications, technologies, architectures, and protocols for computer commu- nication, 359–376 Liu, S; Lin, Y; Zhou, Z; Nan, K; Liu, H; and Du, J 2018 On-demand deep model移动设备压缩: 基于使用驱动的模式选择框架 In Proceedings of the 16th Annual International Conference on Mobile Systems, Applications, and Services, 389–400 Marszałek, M; Laptev, I; and Schmid, C 2009 在上下文中执行动作 In 2009 IEEE Conference on Computer Vision and Pattern Recognition, 2929–2936 IEEE MindSpore 2021MindSopre <https://github.com/mindspore-ai/mindspore> Accessed: 2021-08-01 Mozilla 2021 DeepSpeech <https://github.com/mozilla/DeepSpeech>: 2021-08-01 Ning, L; Guan, H; and Shen, X 20192019 IEEE 35th International Conference on Data Engineering (ICDE)论文: 《Adaptive Deep Reuse: Accelerating CNN Training on the Fly》。作者: Moses Olafenwa。链接: <https://github.com/OlafenwaMoses/Action-Net>。访问日期: 2021年8月1日Traffic-Net: Accessed: 2021-08-01 Passalis, N; Tzelepi, M; and Tefas, A 2020 Heterogeneous knowledge distillation using information flow modeling In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2339–2348 PyTorch 2021 PyTorch <https://github.com/pytorch/pytorch> Accessed: 2021-08-01 Redmon, J; and Farhadi, A 2018YOLOv3 《An incremental improvement》是一篇由Sanh, V; Wolf, T; and Ruder, S在2019年发表在arXiv上的论文预印本。A Hierarchical Multi-Task Approach for Learning Embeddings from Semantic Tasks In Proceedings of the AAAI Conference on Artificial Intelligence, 6949–6956 Selvaraju, R R; Cogswell, M; Das, A; Vedantam, R; Parikh, D; and Batra, D 2020 Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization International Journal of Computer Vision 123(3): 459–473Computer Vision, 128(2): 336–359 Serengil, S I; and Ozzinar, A 2020 LightFace:A Hybrid Deep Face Recognition Framework In 2020 Innovations in Intelligent Systems and Applications Conference (ASYU), 23–27 IEEE Shen, Z, He, Z, and Xue, X 2019 Meal-Multi-model en-semble via adversarial learning In Proceedings of the AAAI Conference on Artificial Intelligence, 4886–4893 Song, C; and Shmatikov, V 2020 Overlearning Reveals Sensitive Attributes In International Conference on Learning Representations Sutskever, I; Vinyals, O; and Le, Q V 2014 Sequence to sequence learning with neural networks In Advances in神经网络处理系统, 3104–3112

Sviridenko, M. (2004). A note on maximizing a submodular set function subject to a knapsack constraint. *Operations Research Letters*, 32(1), 41–43. Tan, C., Sun, F., Kong, T., Zhang, W., Yang, C., & Liu, C. (2018).一份关于深度迁移学习的国际会议论文, 270–279页, Springer, 2021 TensorFlow 2021 TensorFlow, <https://github.com/tensorflow/tensorflow>, 访问日期: 2021-08-01 Tieleman, T; and Hinton, G 2012, Lecture 65-rmsprop: Divide the gradient by a running average of its recent magnitude, COURSERA: 神经网络在机器学习中的应用, 第4期第2期: 26–31页 Tran, D; Bourdev, L; Fergus, R; Torresani, L; and Paluri, M 2015 学习空间和时间特征的三维卷积网络 In Proceedings of the IEEE international conference on computer vision, 4489–4497 Tripuraneni, N; Jordan, M; and Jin, C 2020在迁移学习理论方面的研究任务多样性的重要性 Advances in Neural Information Processing Systems, 33 Wang, G 2021 图像Captioning <https://github.com/DeepRNN/image-captioning> Accessed: 2021-08-01 Wang, J; Fang, Z; and Zhao, H 2020 Alignnet:A unifying approach to audio-visual alignment In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 3309–3317 Xie, X; and Kim, K-H 2019 Source compression with bounded dnn perception loss for iot edge computer vision In The 25th Annual International Conference on Mobile Computing and Networking, 1–16 Yao, A; and Sun, D 2020论文题目: Knowledge Transfer via Dense Cross-Layer Mutual-Distillation In European Conference on Computer Vision 作者: Ye, H-J; Lu, S; and Zhan, D-C 发表时间: 2020 摘要: 本文提出了一种基于密集交叉层互信息的迁移学习方法, 用于在欧洲计算机视觉会议上进行知识转移。该方法利用密集交叉层结构来有效地传递知识, 并通过互信息损失函数来优化学习过程。实验结果表明, 该方法在多个数据集上都取得了良好的性能, 证明了其有效性。Yuan, M., Zhang, L., Li, X-Y., & Xiong, H. (2020a). Comprehensive and efficient data labeling via adaptive model scheduling. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 12396–12405). IEEE. IEEE Yuan, M; Zhang, L; Wu, Z; and Zheng, D 2020b High-quality Activity-Level Video Advertising In 2020 IEEE/ACM 28th International Symposium on Quality of Service (IWQoS), 1–10 IEEE Yuksel, S E; Wilson, J N; and Gader, P D 2012 《IEEE transactions on neural networks and learning systems》第23卷第8期: 1177–1193, 张勇、李翔、托马斯·霍普金斯和吕晓东H 2018 Deep mutual learning In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 4320–4328 Zhang, Y; and Yang, Q 2021多任务学习的调查 IEEE Transactions on Knowledge and Data Engineering Zhou, Z-H 2012 Ensemble methods: foundations and al-CRC Press 出版的算法书籍