

[illegible]

多源模型链接集成 当模型数量 k 大于等于 3 时, 对于一个目标模型 g , 可能会有来自不同源的多模型链接。设 $A = F$ 为源模型集合。那么对于 A 中的所有 $\mathbf{a} \in A$, $g_{\mathbf{a}}$ 执行预测任务, 将 $g_{\mathbf{a}}$ 的输出作为输入。接下来的问题是, 如何确定最终预测结果? 从集成学习的角度来看, $\{g_{\mathbf{a}}\}$ 由 A 构成一个多专家模型 (Yuksele, Wil-son, and Gader 2012), 它可以用多任务和 multimodal 表示更好地进行预测 (Baltru'saitis, Ahuja, and Morency 2018;《张杨 2021》)。我们定义 $h_{\mathbf{a}}$ 为 A 到 g 的 ensemble 模型链接 $h_{\mathbf{a}}$ 是 $g_{\mathbf{a}}$ 预测的集合, 其中 $\mathbf{b}$ 表示第 $\mathbf{b}$ 个样本的标签如如果 $\mathbf{a}$ 只有一个元素 $\mathbf{b}$, 那么 $h_{\mathbf{a}} = g_{\mathbf{b}}$ 。 $\mathbf{f}$ 多模态推理 预算约束模型 这个模型旨在实现多模态推理任务的资源性能权衡 用 $c(\cdot)$ 表示运行一个函数的成本, 比如 GPU 内存或推理时间对于资源有限的设备 (例如智能手表和移动电话) 以及延迟敏感的任务 (例如实时视频分析和音频助手)。在总成本方面有一定的限制。我们定义 B 为成本预算, 并旨在在预算范围内最大化推理准确率。令 $p(h_{\mathbf{a}})$ 表示联合模型的性能指标, 它取决于目标模型的任务。我们假设性能指标的范被归一化为 $[0, 1]$ 。例如, 性能指标可以是准确率对于分类任务和检测任务的精度和 F1 分数 IoU, 我们可以参考之前优化推理效率的努力 (Li 等人, 2020 年; Yuan 等人, 2020 年 a)。将多模型集成在成本预算约束下的推理问题形式化为:

平均输出准确率

$$\max_A \left(\mathbb{E}_{\mathbf{f} \in A_1} \left[\sum_{\mathbf{g} \in F \setminus \Delta p(h_A, j)} \right] \right)$$

s.t. $\mathbf{f}$ 属于 A_c $\mathbf{g} \in F \setminus \Delta c(h_A, j)$ $\leq B$

我不太明白
白您的意

~~del~~ links ~~del~~ mo

在成本预算下,优化问题的旨在通过选择执行的激活子集 A 来最大化网络输出 F 的平均性能。为了便于描述,我们定义了目标函数为输出函数。激活模型进行精确推理,因此其性能分数均为1。未激活的模型仅参与构建模型链接,而在推理阶段不会执行;相反,它们被预测为模型链接的一部分。通过 ensemble model links 激活模型和激活模型的费用是执行精确的推理,而预测模型的费用是从运行模型链接中获得的。因此,模型链接应该既准确又轻量级,以减少成本,同时保持多模型推理工作的质量。

是：通常，对齐输入空间存在于多模态场景的上下文中g, multi-modality event detection (Elho- seiny et al 2016) and visual speech synthesis (Baltru'saitis, Ahuja, and Morency 2018)在实践中，时间同步可以轻松地将输入对齐 for many applications。此外，诸如 Black, Ellis 和 Rosin (2002) 提出的多视图视频空间对齐和音频- 视频同步等方法也可以用于对齐mantic alignment (Wang, Fang, and Zhao 2020) can be adopted for specific scenarios We define model linking as a function $g_{ij} : Y_i \text{ 转换为 } Y_j$ ，即从源模型 $\hat{g}$ 的输出空间到目标模型 Y_j 的映射 f_j 's然后复合函数 $g_{ij} \circ f_i : X_i$ 可以执行 f_j 的推理计算。相应地， g_{ji} 将 f_i 的知识链接到 $g_{ji} \circ f_j$