

黑盒模型链接

在这个部分，我们讨论了将黑盒模型链接起来的动机，并提出了模型链接的理论分析、架构设计、集成和训练方法

激励学习

在为不同的任务训练机器学习模型时，理想的模型学习的表示应该是独立的且相互独立的（Hjelm等人，2019年），即每个模型只学习其目标任务的语义。然而，由于数据和模型的复杂性不匹配，机器学习过程容易出现“过拟合”（Song和Shmatikov，2020年），这意味着意外的语义被编码在学习的表示中。此外，输出之间存在语义相关性不同的任务和不同的模型可能会关注相同的内容，例如图像中的相同区域。例如，在图1a中，基于G-CAM（Selvaraju等人）的模型和基于注意力机制的模型可能会关注图像中的相同区域。2020年我们绘制了YOLO-V3（Redmon and Farhadi 2018）对象检测器和ResNet50（He et al 2016）的注意力热图场景分类器在相同的图像上进行分类，它们的注意力区域有很大的重叠。我们对注意力热图重叠比与模型链接性能之间的相关性进行了实验。例如，从场景分类器到对象检测器，如图1b所示，模型链接的准确性显然与注意力热图重叠比((Mapsource $\wedge$ Maptarget)/Maptarget)有关在一定程度上，模型学习到的关联链接与语义注意力相似。这种“过学习”特性以及输出之间的潜在语义相关性使得从相同的或对齐的输入空间到不同的输出空间的映射可转移（Tan et al. 2018）

一个关键的设计原则是，我们只使用源模型的黑盒输出来进行模型链接。已有的研究表明，通过微调最后几层（Guo et al, 2019），中间表示可以用于预测其他不同的任务。然而，在实际应用中，我们经常需要处理部署的模型，这些模型只提供黑盒推理API。与中间表示相比，下游的黑盒输出具有较弱的表示能力。但是最近的工作（Yuan et al. 2021）表明，对于一般学习任务，这种策略并不总是有效的。2020a)给定相同的输入，执行模型的输出是未执行模型调度的有效提示。这一洞察是，多个任务具有相同输入时黑盒模型输出之间的相关性更明确甚至更强。我们的实验结果还表明，使用相同量的训练数据，黑盒模型链接的准确性高于知识蒸馏方法（见图2）和多任务学习方法考虑到更好的实用性以及满意的准确性，我们选择黑盒输出而不是中间表示来链接机器学习模型




图1：不同模型之间的语义相关性

样本复杂度分析

f 属于 F 表示任务特定参数， h 表示在任务之间共享的参数。已经证明，当 h 的训练数据充足时，只需要 $C(F)$ 样本复杂度（Tripuraneni, Jordan, and Jin 2020），就可以在新任务上达到有限的预测误差。 $C(\cdot)$ 表示一个假设族的复杂度。学习一个链接 g_{ij} 属于 G 的模型，从源模型 f_i 学习 $In F_i$, the target f_j belongs to F_j , and the compound learning model $g_{ij} \circ f_i$ represents the process of combining F_i and f_j to form g_{ij} . 轻量级模型链接设计可以使 $C(G) < C(F)$ 成立。因此，应用上述结果，模型链接可以显著降低学习目标模型的样本复杂度，与从头学习目标模型的 $C(F)$ 复杂度相比。这个结果也被我们的实验所证实：有效的模型链接模型结构少量的训练样本（例如1%）来学习（见图2）。黑盒模型的输出空间之间的映射模型，因此输出格式决定了架构。我们把输出格式分为固定长度向量和变长序列。这两种输出可以涵盖大多数机器学习模型。我们根据类似的学习任务的最佳实践提出四种模型链接架构。Vec-to-Vec：模型链接从向量输出源到向量输出目标。我们使用ReLU激活的多层感知器

（MLP）作为vec-to-vec模型链接Seq-to-Vec：模型将序列输出源映射到向量输出目标 我们首先使用一个嵌入层，它将序列映射到一个固定大小的嵌入。然后我们使用一个LSTM（Hochreiter and Schmidhuber 1997）层，接着是一个MLP来生成向量输出。Vec-to-Seq：模型链接从一个向量输出源到一个序列输出目标。我们采用编码器-解码器框架，其中MLP作为编码器，解码器由一个嵌入层，一个LSTM层和一个注意力层（Bahdanau, Cho, and Vinyals 2014）组成。这是在讨论一个神经网络模型，其中包含一个双向长短期记忆层（Bi-LSTM）和一个全连接层。这个模型将一个序列输出的源映射到一个序列输出的目标。我们采用了序列到序列（Seq2Seq）框架（Sutskever, Vinyals和Le 2014），其中嵌入层和LSTM层作为编码器，解码器与vec-to-seq模型中的解码器相同。