

输出激活函数是由目标模型的学习任务决定的，对于单标签分类，使用softmax，对于多标签分类和序列预测，使用sigmoid线性激活函数可用于回归和定位任务。在我们的实现中，默认的隐藏单元数量是输出维度的两倍，这在有效性与效率之间实现了良好的权衡。

多源链接集合模型有潜力提高预测性能(Shen, He, and Xue 2019)，因为跨任务和跨模态表示能力是有益的。对于目标模型 f_j ，给定源集 A ，我们乘以 g_{ij} 的输出 trainable weights, where $f_i \in A$ 根据 f_j 的学习任务，使用 $h_{A,j}$ 学习到的权重来组合模型链接，来自任何子源集 $i \in A$, $A' \subset A$

在经典知识蒸馏 (Hinton、Vinyals和Dean 2015) 中，训练“学生”模型时，软标签监督比硬标签监督更好，因为“教师”模型的输出可以为不同类之间的关系增加硬标签空间。我们的实验结果表明，在提出的模型中，这种经验仍然适用。为了训练模型链接和ensemble模型，我们收集了 n 个推断结果 $\{y_j\}_{j=1}^n$ $n=1$ from k models on the same or aligned inputs Given f_i, f_j as the source and the target, respectively, the objective of training the model link g_{ij} is $\min_{g_{ij}} L_j(g_{ij}(y_i))$ and $y_l(j)$ are the input and output of the j -th layer of the target model f_j , respectively. The loss function L_j depends on the learning task of the target model f_j . 给定源集合 A 和目标集合 f_j ，训练联合模型 $h_{A,j}$ 的目标是：对于任意的 y_l 和 $f_i \in A$ ，最小化损失函数 $\Delta(A, f_i) = F(A \cup \{f_i\}) - F(A)$ 。假设将一个源模型链接到集成模型中不会降低性能，则： $p(A \cup \{f_i\}) \geq p(A)$ 根据周(2012)的实证研究， $p(A, f_j)$ 是真实的那么 $\Delta(A, f_i) \geq 0$ 在我们的实验中，我们观察到了两种典型情况：(1) 主导地位 堆栈模型的性能大约等于最佳性能源模型链接 Let $f_i^* = \arg\max_{f_i \in A} p(g_{ij})$ 定义为 f_i^* 为 A 中 g_{ij} 的最佳性能源模型链接笔记来源：在性能最优的情况下，我们观察到 $p(h(A, f_i)) \approx p(g_i^*)$ ，即(1) 最优源主导集成性能 (2) 互助 多源模型将集成优于任何单一源对于所有 $f_i \in A$, $p(h(A, f_i)) > p(g_{ij})$ ，即模型链接的来源相互辅助。在这种情况下，如果 f_j 与 A_2 中的模型协作更好，那么 f_j 为 A_2 带来的收益可能大于为 A_1 带来的收益，因为 A_1 包含 A_2 。

算法1: 协同多模态推理

输入: 模型集 F , 成本预算 B

对于任意的 $f_i, f_j \in F, i \neq j$, 训练模型链接 g_{ij}

对于每一个 f_j 属于 F , 训练一个ensemble模型 $h_{A,j}$, 其中 $A_j = F \setminus \{f_j\}$

每步耗时30分钟

4 Profiling activation probability of $f_i \in F$

贪婪地选择 A ，直到达到成本预算 B ，其中 A 是 F 中

$\arg\max_{f_i \in F \setminus A(P_i)}$ 的集合

Given incoming input x , for $f_i \in A$

如果 f_i 属于 A , 则: $y_i \leftarrow f_i(x)$

8 else: $y_i \leftarrow h_{A,i}(y_j) f_j \in A$.

我不

太明

白您

激活概率求解方程(1)是NP-hard的，并且 $(1-e^{-1})$ -近

似算法(Sviridenko 2004)需要部分枚举，并且需要

(1-5)计算目标函数 优化不是一个一次性的过程，而

是在线上执行以适应推理系统的动态。因此，我们

提供了一个启发式激活概率指标，其计算只依赖于模

型链接的性能，而不是ensemble模型的性能。给定一

个模型 f_i ，激活概率可以计算为：

$P(f_i) = \frac{1}{n} \sum_{j=1}^n P(f_i | f_j)$ 其中 $P(f_i | f_j)$ 表示第 j 个

模型状态在模型 f_i 下的概率， $P(f_j | f_i)$ 表示第 j 个激活

状态在模型 f_i 下的概率， $P(f_i)$ 表示第 j 个激活状态的概

率。这个激活概率指标 $P(f_i)$ 表示模型 f_i 对其他所有模型的

平均性能，表示为 $P(f_i)$ 。

where the weight w can be determined

by the following normalization By regularizing

the range into 0 to 1, we have $(1 + 1 - 0)/(w$

$\min_i(c(f_i)) = 1$, ie, $w = 2 / \min_i(c(f_i))$ 这个激活概率可

以被认为是一个正相关于选择机器学习模型目标函数

增益的系数。周期性重新选择由于内容的动态性，最

优激活模型的子集可能会随着时间变化。但是适应这

种动态性会带来额外的加载和卸载机器学习模型的费用。

因此，我们提议定期重新选择激活的模型。在每个

时期开始时，我们使用一小部分（例如1%）的数据

来评估模型链接的预测性能Then we update ML

models' activation probabilities and re-select

models to be loaded during the current period

By reason- ably setting the period length and the

proportion of data used for profiling, we can

amortize the overheads of load- ing/unloading

ML models to negligible Algorithm 1 shows the

workflow of整合MLinks与多模态推理工作负载。最

初，我们训练pairwise模型链接和ensemble模型。

在每个时期，我们首先通过运行所有模型在数据上进

行profile，然后选择贪婪算法来选择最相关的模型。

接下来，我们使用MLinks将这些模型链接起来，并将

其应用于多模态推理工作负载。在服务阶段，激活的

模型进行精确推断，而其他模型的输出将由激活源的

模型链接 ensemble 预测