

任务: ClassML Model 输入: Modality 输出: FormatMetric
 Single-Label Classification Gender Classification (Kumar 2021) Audio2-D Softmax Labels Acc.
 多标签分类 (Tran et al. 2015) 视频12-D Sigmoid标签 mAP
 LocalisationFace Detection (Serengil and Ozpinar 2020)Image4-D Bounding BoxIoUPerson Detection
 (Redmon and Farhadi 2018)Image
 RegressionAge Prediction (Levi and Hassner 2015)Image1-D ScalarMAE
 Sequence GenerationImage Captioning (Wang 2021)ImageVariable-Length TextWERSpeech Recognition
 (Mozilla 2021)Audio

Table 1: 洛杉矶2数据集上使用的机器学习模型总结

我们基于TensorFlow 20 (TensorFlow 2021) 在Python中实现了我们的设计, 作为推理系统的插件式中间件1我们测试了使用TensorFlow (TensorFlow 2021)、PyTorch (PyTorch 2021) 和MindSpore (MindSpore 2021) 编写的程序, 只需要几十行代码的修改, 就可以使用MLink, 这表明MLink的易用性。我们对我们的设计在多模态数据集和两个实际的视频分析系统上进行了评估多模态数据和机器学习模型 我们使用了好莱坞2视频数据集 (Marszalek, Laptev, and Schmid 2009) 来获得多模态模型的对齐输入。我们选择了每段视频的第30帧, 并从中提取了音频数据。我们部署了七种预先训练的机器学习模型, 涵盖了五类学习任务: 单标签和多标签分类、回归和生成。多标签分类, 对象定位, 回归和序列生成是不同的任务, 它们有不同的模型架构, 输入模式和输出格式。为了评估模型链接的性能, 我们使用了特定任务的指标, 包括准确性, 平均平均精度 (mAP), 边界框交并比 (IoU) 和平均绝对误差 (MAE) 和 (WER)Table 1总结了这些ML模型在智能建筑和城市交通监测系统中的应用我们对MLink在两个实际的视频分析系统上进行了评估1. 智能建筑 支持包括自动空调和照明的应用程序, 以及异常事件监控这三个模型分别是: 监督学习、房地产安全和财产安全 OpenPose (Cao et al 2019)-基于的人数计数, ResNet50 (He et al 2016)-基于的动作分类 (Olafenwa 2021a), YOLOV3 (Redmon and Farhadi 2018)-基于的对象计数 我们收集了两天 (一个工作日和一个周末) 的视频帧, 来自所有58个摄像头 (每分钟1帧) 我们使用边缘检测算法来检测视频中的物体, 并使用这些检测结果来计算物体的数量一台服务器, 配备一块NVIDIA 2080Ti显卡在城市规模的视频分析平台上, 部署了三个AI模型用于交通监测: 基于Open-Pose的人员计数、基于ResNet50的交通状况分类 (Olafenwa 2021b) 和基于YOLOV3的车辆计数。我们在路口选择了10台摄像机, 连续采集了2天 (一个工作日和一个周末) 的帧 (每秒1帧) 我们使用了5台服务器, 每台服务器配备4个NVIDIA T4 GPU

我们介绍了一种简单的独立推断方法和三种强大的替代资源性能权衡方法作为基线 (1) 独立推断: 独立运行模型 (2) MTL: 我们采用了一种多任务学习架构 (Crawshaw 2020), 该架构包括一个全局特征提取器, 由所有任务共享, 以及针对每个任务的输出分支。我们还采用了 (3) 模型融合: 将多个模型的输出融合在一起, 以获得更好的性能。使用ResNet50 (He et al, 2016) 实现特征提取器和全连接层, 用于特定任务输出。我们使用ImageNet (Deng et al, 2009) 预训练的ResNet50特征提取器, 并连接三个输出分支用于人数计数, action/traffic classification, and object/vehicle count-任务是基于智能建筑和交通监测测试床的MTL模型训练。这些模型是在相应的模型的精确推断结果监督下训练的(3) Reducto (Li et al. 2020): 一种帧过滤方法 对于每个模型, Reducto首先计算相邻帧之间的特征差异 如果特征差异低于一个阈值, 它将过滤掉当前帧并重新使用最新的推理输出 我们测试了四种低层次的特征根据 Reducto提出的建议, 我们选择了性能最佳的方案 (4) DRIS (基于深度强化学习的调度程序) (Yuan et al. 2020a) 和多模型调度方法DRIS使用深度强化学习 (Crawshaw 2020) 来调度模型 我们使用了一个模型调度器来执行模型的输出 为了测试不同大小的训练数据对模型链接性能的影响, 我们进一步随机抽取了四个不同的训练数据集, 每个数据集的大小分别为: 200、400、600、800个视频剪辑。我们使用了10%、20%、50%和100%的训练数据比例, 相对于总数数据集。我们使用RMSprop (Tieleman and Hinton 2012) 优化器和相同的超参数 (学习率为0.001, 训练周期为100, 批量大小为32)。为了公平比较, 我们采用了知识蒸馏Hinton, Vinyals, and Dean在2015年提出了一种方法, 用于一些目标模型 (Action, Age, Gender) 中, 其中学生模型具有两个卷积层我们重复了三次实验, 并报告了性能的平均值和标准差。如图2所示, 使用所有训练数据, Caption-to-Action模型链接可以达到317% mAP。而模型链接之间的两个检测模型, Face-to-Person和Person-to-Face模型链接, 可以达到59% 和 32% IoU 分别, 即使有非常有限的训练样本, 一些模型链接也能达到很高的性能