

Target \ Source Action Age Caption Face Gender Person Speech Ensemble
 Action mAP(%)12.8(±1.3)29.7(±1.4)10.1(±1.3)9.3(±0.3)9.9(±1.2)8.5(±3.1)30.8(±1.1)Face
 IoU(%)11(±1.3)11.2(±1.0)0 (±0)-10.3(±0.9)31.9(±0.3)0 (±0)32.2(±0.2)Person
 IoU(%)39.4(±0.1)38.9(±0.1)0(±0)58.5(±1.3)39.0(±0.1)0(±0)59.2(±1.2)
 Age MAE3.04(±0.01)3.02(±0.01)3.07(±0.02)3.0(±0.01)3.03(±0.01)3.0(±0.01)2.98(±0)Gender Acc.
 (%)92(±0.1)92.1(±0.2)92(±0.1)92.1(±0.1)-92(±0.1)92(±0.1)92.3(±0)

Table 3: 模型链接集成中的主导和相互帮助案例。列标题是源模型，行标题是目标模型。主导源的性能以粗体显示。

Method	Building (5/9GB Mem.)	City (5/9GB Mem.)
	Acc. (%)	Time (ms)
Standalone	33.3/66.730	7433.3/66.755/121
MTL	53.332.861.332.5DRLS	45.7/81.358.7/10739.5/77.6102/188
Reducto	91.8/96.945.7/8984.1/95.364	127
MLink	94.1/97.939.3/8494/97.462	125

表4：MLink, MTL, Reducto, DRLS和 Standalone方法在两个视频分析系统上的比较

相关工作

多任务学习和压缩一种直接优化多个独立机器学习模型的方法是多任务学习 (Sanh, Wolf和Ruder 2019; Caruana et al. 2001)。在多任务学习中，模型在多个任务上共享参数，从而减少了训练和推理的计算成本。此外，多任务学习还可以提高模型的泛化能力，因为模型可以从共享参数中学习更多的通用知识。张和杨(2021)和压缩(He, Zhou和Thiele, 2018)多任务模型可以在相同成本预算下提供比单任务模型更丰富的推理结果。但是，多任务学习方法缺乏灵活性和可扩展性，即我们需要为每个案例单独设计多任务解决方案，并且一旦设置更改，就需要重新设计。任务的变化相反，尽管不同黑盒机器学习模型之间存在参数冗余，MLink方法可以灵活扩展。实验表明，当给定少量训练数据时，模型链接的准确性更高。知识蒸馏根据最近的分类法，知识蒸馏可以分为三类：知识迁移、知识压缩和知识融合。知识迁移是将源模型的知识转移到目标模型中，从而提高目标模型的性能。知识压缩是通过减少源模型的知识量来减少目标模型的大小。知识融合是将多个源模型的知识融合在一起，从而获得更好的性能。2021年，Gou等人的研究表明，知识蒸馏有三个主要的知识来源：(1)响应(Ba和Caruana 2014; Hinton, Vinyals和Dean 2015): 教师模型的输出；(2)特征(Chen等 2021): 中间特征图；(3)关系(Passalis, Tzelepi和Tefas 2020): 关系特征映射Zhang et al. (2018) 和 Yao and Sun (2020) proposed mutual distillation, which trains an ensemble of "student" models and lets them learn from each other mutually. Ye, Lu, and Zhan (2020) proposed cross-task distillation, which trains a "student" model by a "teacher" model pre-trained for another task.Model link-我方大明白您的意思

一种基于强化学习的多模态数据标注任务调度算法，利用已执行模型的输出作为提示信息来调度剩余模型Reducto (Li et al. 2020)通过设置相邻帧特征差异的阈值来过滤视频帧 DNNs-aware video streaming (Xie and Kim 2019; Kim et al. 2020)通过利用深度神经网络 (DNN) 的输出来优化视频流的传输Du et al.2020年提出了一种用于通信效率优化的推理精度压缩方法FoggyCache (Guo et al. 2018)利用自适应哈希输入值来重用缓存的推理结果。我们提出MLink调度程序以一种新颖且更直接的方式优化成本效率：通过已执行模型的输出预测未执行机器学习模型的推理结果

结论和讨论

在这个工作中，我们提出将黑盒机器学习模型链接起来，并提出模型链接的设计和一种协作的多模型推理算法综合评估表明黑盒模型链接的有效性以及MLink相较于其他替代方法的优越性。我们总结了以下局限性和未来工作：(1) 当源模型和目标模型之间的语义相关性较低时，模型链接的输出准确性较差当联合模型的数量非常大的时候， pairwise模型链接将变得不实用我们未来将研究如何智能地选择模型来构建模型链接 (3)。由于参数量较小，重新训练的成本很小（eG, a vec-to-vec model with 100-dimensional input and output lengths, costs 129 seconds for training 100 epochs using 1,000 samples. Therefore, a periodic retraining policy for updating MLink is feasible.我们将会研究在线学习和主动学习机制，以进一步提高MLink对输入动态的适应性并减少更感谢

这项研究得到了中国2021年国家重点研发计划的支持，以及中国2018年国家重点研发计划的支持，同时得到了中国国家自然科学基金的资助，编号分别为61822209、62132018、61932016和61932017这是中国科学技术协会-华为“基础科学基金”资助的项目，项目编号为61625205