

基因型使得设计一个通用的模型来描述机器学习模型之间的知识水平联系具有挑战性另一方面，模型链接应该是对原始推理系统无干扰的，并且尽可能少地需要模型信息和代码修改机器学习模型的黑盒访问给设计和实现带来了额外的挑战（2）

如何有效地选择要执行的模型和要预测的模型？给定一组机器学习模型，构建它们之间的模型链接之后，我们需要在一定的成本预算下选择合适的子集模型执行，例如可分配的GPU内存。高效模型选择对于成本效益权衡至关重要，由于其理论难度，这是一项非线性任务在本文中，我们首先形式化了模型链接任务，并提出了支持链接异构黑盒机器学习模型的设计。我们开发了一个基于链接的模型调度算法，名为MLink，用于在成本预算下调度多模态推理。我们对七种不同的机器学习模型在多模态数据集上进行了评估，涵盖了五类学习任务和三种输入模态结果显示，我们提出的模型链接可以有效地将异构黑盒模型连接起来我们对MLink在两个实际的视频分析系统上进行了评估，一个是用于智能建筑的，另一个是用于城市交通监控的，包括六个视觉模型和58个摄像头的3264小时视频。在GPU内存预算下，MLink优于基线（多任务学习（Crawshaw 2020）、基于深度强化学习的调度器（Yuan et al. 2020a）和帧过滤（Liet al. 2020）），可以节省66.7%的推理计算，同时保持94%的输出精度

Problem Statement

在这个部分，我们定义了模型链接任务和在预算约束下的推理问题模型链接给定一组黑盒机器学习模型 $F = \{f_i\}_{i=1}^K$ ，其中 $f_i: X_i \rightarrow Y_i$ 是一个函数，将输入映射为推理结果。机器学习模型可以非常多样化，即不同的输入模态，学习任务，架构等。我们假设输入空间 $\{X_i\}_{i=1}^K$ 是相同的或对齐的不同的模型共享相同的输入空间是很常见的，例如多任务学习在机器人中的应用（Crawshaw 2020；Zhang and Yang 2021）和多媒体广告（Yuan et al. 2020b）。对齐输入空间通常存在于多模态场景中，例如多模态事件检测（Elho-seiny et al. 2016）和视觉语音合成（Baltrušaitis, Ahuja, and Morency 2018）。实际上，同步时间可以很容易地为许多应用程序对齐输入此外，Black, Ellis和Rosin（2002）提出的多视频空间对齐方法以及Wang, Fang和Zhao（2020）提出的音频-视觉语义对齐方法可以用于特定场景我们定义模型链接为一个函数 $g_{ij}: Y_i \rightarrow Y_j$ ，即源模型 f_i 的输出空间到目标模型 f_j 的映射然后复合函数 $g_{ij} \circ f_i: X_i \rightarrow Y_j$ 可以执行 f_j 的推理计算相应地， G_{ji} 链接了 F_i 的知识到 $G_{ji} \circ f_j$

多源模型链接集成当 k 大于等于3时，对于一个目标模型 f_j ，可能会有多个来自不同源的模型链接 A 表示源模型的集合那么对于所有的 f_i 属于 A ， $g_{ij} \circ f_i$ 执行预测任务，将 f_j 的输出作为输入接下来的问题是，我们如何确定最终预测结果从集成学习的角度来看， $\{g_{ij} \circ f_i\}_{f_i \in A}$ 构成一个多专家模型（Yuksel, Wilson, and Gader 2012），它具有在多任务和多模态表示下进行更好预测的潜力（Baltrušaitis, Ahuja, and Morency 2018；Zhang and Yang 2021）。我们定义 $h_{A,j}$ 为 A 到 f_j 的ensemble模型链接输入 $h_{A,j}$ 是由 g_{ij} 预测的集合，其中 f_i 属于 A 。注意，如果 A 只有一个元素 f_i ，则 $h_{A,j}$ 等于 g_{ij} 与 f_i 的乘积。在预算范围内进行多模态推理模型links can用于实现多模型推理工作负载的资源性能权衡设 $c(\cdot)$ 表示运行函数的成本，例如GPU内存或推理时间对于资源有限的设备（例如智能手表和移动电话）以及延迟敏感的任务（例如实时视频分析和音频助手），总成本有一定的限制我们定义 B 为成本预算，并旨在在预算范围内最大化推理精度Let $p(h_{A,j})$ denote the performance measure of the ensemble model link, which depends on the target model's task. 我们假设 p 的取值范围被归一化到 $[0, 1]$ 例如，对于分类任务，性能指标可以是准确性；对于检测任务，性能指标可以是边界框IoU。在优化推断效率（Liet al. 2020；Yuan et al. 2020a）的基础上，我们采用了衡量推断结果与精确推断输出一致性的方式作为性能指标，而不是精确标签多模态在成本预算约束下的推理问题被形式化为：

$$\begin{aligned} \max_{A \subseteq F} & \left(\frac{1}{|F|} \left(\underbrace{\sum_{f_i \in A} 1}_{\text{activated}} + \underbrace{\sum_{f_j \in F \setminus A} p(h_{A,j})}_{\text{predicted}} \right) \right) \\ \text{s.t.} & \underbrace{\sum_{f_i \in A} c(f_i)}_{\text{exact inference}} + \underbrace{\sum_{f_j \in F \setminus A} c(h_{A,j})}_{\text{model links}} \leq B. \end{aligned} \quad (1)$$

在成本预算下，优化问题的目标是通过选择执行的激活子集 A 来最大化所有模型 F 的平均性能为了便于描述，我们定义目标函数为输出精度激活模型进行精确推断，因此它们的性能分数都是1未激活的模型仅参与构建模型链接，而在推理阶段不会执行；相反，它们通过ensemble模型链接被激活的模型预测。激活模型的费用是执行精确推理，而预测模型的费用是从运行模型链接中获取的模型链接应该既准确又轻量级，以减少成本，同时保持多模态推理任务的质量