

1. 介绍

循环神经网络（Recurrent Neural Networks, RNNs），特别是长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环神经网络（Gated Recurrent Neural Networks, GRU），已经被证明是序列建模和转换问题的最佳方法，例如自然语言处理和机器翻译等任务。自那时以来，已经持续不断地在循环语言模型和编码器-解码器架构的边界上推动这些技术的发展。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间的步骤上，从而生成一个隐藏状态序列 h_t ，作为前一个隐藏状态 h_{t-1} 和输入序列 t 的函数。

并行 nature 意味着在训练例子中无法并行化，这在对长序列长度时变得至关重要，因为内存限制阻止了在例子之间进行批量。最近的工作通过因子分解技巧和条件实现显著提高了计算效率。

计算，同时提高在后者中的模型性能 Attention 机制已经成为各种任务中序列建模和生成模型的关键组成部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离 In all but a few cases, such attention mechanisms are used in conjunction with a recurrent network 在这项工作中，我们提出了Transformer模型架构，该模型架构不依赖于循环，而是完全依赖于注意力机制来绘制输入和输出之间的全局依赖关系。Transformer允许实现显著的并行化，可以在训练时间为12小时的情况下，达到与现有技术的翻译质量达到的新水平。

2背景

减少序列计算的目标也构成了扩展神经网络GPU的基础，如ByteNet和ConvS2S，它们都使用卷积神经网络作为基本构建模块，对输入和输出位置并行计算隐藏表示。在这些模型中，从两个任意输入或输出位置相关联的操作用于增加距离，线性地对于ConvS2S模型。

对于 ByteNet，通过对数函数进行规划，这使得在远离的位置学习依赖变得更加困难。在 Transformer 中，这一问题已经被减少到常数。

操作次数，尽管因为平均注意力的加权位置而降低了有效分辨率，但我们可以抵消这种影响。

3.2 中的多头注意力