

1. 介绍

循环神经网络（RNNs）、长短期记忆网络（LSTM）和门控循环神经网络（GRU）已经在序列建模和转换问题（如自然语言处理和机器翻译）中成为了状态引领的方法。自那时以来，已经持续朝着循环语言模型的边界和编码器-解码器架构的极限努力。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间中的步骤，从而生成一个隐藏状态 h_t ，作为前一个隐藏状态 h_{t-1} 和输入序列的位置 t 的函数。

并行化在训练实例中并不保证连续性，这在对长序列长度时变得至关重要，因为内存限制会阻止在实例之间进行批量。最近的工作通过因子分解技巧和条件实现显著提高了计算效率。

计算，同时提高模型在后者中的性能。然而，序列计算的基本约束仍然是注意力机制已成为各种任务中引人注目的序列建模和传输模型的关键组成部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离。然而，在大多数情况下，这些注意力机制都是与循环神经网络一起使用的。在这项工作中，我们提出了Transformer，一种不使用循环结构，而是完全依赖注意力机制来确定输入和输出之间的全局依赖关系的模型架构。Transformer允许实现显著的并行化，可以在训练时间为12小时的情况下，达到与现有水平相媲美的翻译质量。

2. 背景

减少序列计算的目标也构成了扩展神经网络GPU的基础，ByteNet和ConvS2S，它们都使用卷积神经网络作为基本构建模块，对输入和输出位置计算隐藏表示并行计算。在这些模型中，从两个任意输入或输出位置将信号进行关联所需操作的数量在位置之间随距离线性增加，对于ConvS2S模型。

对ByteNet进行对数操作。这使得在远离的位置学习依赖变得更具挑战性。在Transformer模型中，这被减少为常数。

操作次数，尽管因为平均注意力的加权位置而降低了有效分辨率，但我们可以抵消这种影响

3.2节中描述的多头注意力