

1. 介绍

循环神经网络（Recurrent Neural Networks, RNNs），特别是长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环神经网络（Gated Recurrent Neural Networks, GRU），已经在序列建模和转换问题（如自然语言处理和机器翻译）中取得了state-of-the-art的进展。自那以后，已经持续不断地在循环语言模型和编码器-解码器架构的边界上推动循环神经网络的改进。递归模型通常会沿着输入和输出序列的符号位置进行计算，将位置对齐到计算时间中的步骤，从而生成一个隐藏状态序列 ht ，作为前一个隐藏状态 $ht-1$ 和输入序列的位置 t 的函数。

并行化在训练数据中并不总是可能的，这在一个较长的序列长度中变得非常重要，因为内存限制会阻止在示例之间进行批量处理。最近的工作通过分解技巧和条件分解达到了显著的计算效率改进。

计算，同时提高模型在后者中的性能。序列计算的基本约束仍然是注意机制已成为各种任务中引人注目的序列建模和转换模型的关键组成部分，允许在输入或输出序列中建模依赖关系，而无需考虑它们之间的距离。然而，在大多数情况下，这些注意机制与递归网络一起使用。在我们的工作中，我们提出了Transformer模型架构，该模型不使用循环结构，而是完全依赖注意力机制来绘制输入和输出之间的全局依赖关系。Transformer允许实现大幅度的并行化，可以在训练时间为12小时的情况下，达到与当前最先进的翻译质量达到的新水平。

2. 背景

减少序列计算的目标也构成了扩展神经网络GPU的基础，如ByteNet和ConvS2S，它们都使用卷积神经网络作为基本构建模块，并平行计算所有输入和输出位置的隐藏表示。在這些模型中，將來自兩個任意輸入或輸出位置的信號進行關聯所需的操作在位置之間增加，對於ConvS2S模型是線性的，對於其他模型則不是線性的。

对ByteNet进行logarithmic变换，这使得在远离的 positions之间学习依赖变得更加困难。在Transformer模型中，这已经被减少为常数。

操作次数，尽管由于平均注意力的加权位置而降低了有效分辨率，但我们还是可以应对的。

3.2中的多头注意力