

表 3 彭博新闻数据汇总统计, 包括文章数和每篇文章相关标签的密度。样本的统计摘要包括每个变量的均值、中位数和四分位数; 样本中每年的均值也单独给出。

每日文章 每日文章带有安全码	每日文章, 包含证券代码和相关 性大于等于70	文章标签
全样本		
平均值 70, 723 29, 570 4, 026 1.30		
中位数 60, 783 25, 212 2, 675 1.26		
第 25 百分位数 31, 668 12, 353 1, 311 1.22		
第 75 百分位数 94, 010 41, 785 6, 032 1.37		
按平均值		
2000 20,940 8,727 940 1.60		
2001 23,844 9,692 1,062 1.40		
2002 26,844 10,621 1,159 1.39		
2003 30,190 12,458 1,309 1.32		
2004 33,417 14,432 1,577 1.27		
2005 38,251 16,372 1,582 1.26		
2006 47,784 20,753 2,194 1.21		
2007 60,024 24,775 2,596 1.22		
2008 66,819 27,258 2,673 1.20		
2009 75,303 28,976 2,777 1.18		
2010 82,227 36,901 3,774 1.22		
2011 93,058 42,208 5,966 1.25		
2012 102,778 45,471 6,096 1.25		
2013 170,409 69,775 12,582 1.35		
2014 188,964 75,128 14,106 1.37		

足够。他们可能会谈论 6 RM 的主要竞争对手。相关性得分约为 50 % 的物品仅与所讨论的安全性相关。 11

我们的分析样本包含至少70%的相关性且至少被分配给一个美国上市股票的新闻文章。对于被认为是至少70%相关的文章, 我们包括所有相关性为70%或更高的安全标签。这将样本限制在每天大约40000篇新闻文章, 每篇文章链接到平均1.3张证券。

3月1日, 旧闻

我们使用每篇文章前一篇文章中关于相同安全主题的文本所涵盖的程度来代理旧信息在新闻中的使用。对于样本中的每篇文章, 我们首先提取文章文本中的唯一单词(单个单词)。我们[删除停用词(如 "a", "the", "in", "when" 等常见单词)并使用Porter (1980) 的标准词干算法将所有单词转换为唯一的术语(因此, "earned" 和 "earnings" 将被表示为相同的术语 "earn")。我们使用范数 ||·||₁ 表示一组文章中独特的术语数量。例如, \$s_1\$'cap s_2\$ 是 \$s_1\$ 和 \$s_2\$ 中独特的术语的个数我们通过文章数之前文章涵盖的程度来衡量每篇文章的旧内容。对于每个被标记为 \$firm\$ 的 article, 我们查看所有被标记为 \$s\$ 的 \$article\$ that

我也被标记为 \$i\$, 并且会在 \$s\$ 发布前的三天 (72小时) 内被发布。我们识别出五篇文章 (\$s_1, s_2, \dots, s_5\$), \$s_1\$ 单独跨越 \$s\$ 和 \$de\$ 中最大部分的术语, \$s\$ 包含旧信息的程度为:

$$ID(s) = \frac{|s \cap (S \setminus s)|}{|s|} = \frac{|s \cap (S \setminus s)|}{|s|} \quad (5)$$

我们衡量旧内容的方法类似于 Tetlock (2011) 引入的方法论, 其中有一个关键创新。我们不再将旧内容定义为与最近的前几篇文章中相邻的段落平均值, 而是考虑前几篇文章的整体百分比覆盖范围。这段话的意思是: (i) 文章 \$s_1\$ 和 \$s_2\$ 在第一段中部涵盖了关于公司的背景信息 (占文章文本的 50%), 但除此之外讨论的是完全不同的事实; (ii) 文章 \$s_1\$ 和 \$s_2\$ 涵盖了完全相同的信息 (交集为 100%), 而 \$s_1\$ 与 \$s_2\$ 完全不交集。使用平均交集度量法, \$s\$ 在这些两个情况下会被认为类似相等 (50%), 尽管在情况 (i) 中它包含新的信息。在情况 (ii) 中它什么都没有包含。基于术语覆盖的度量方法可以避免这个问题。在未发表的分析中, 我们还证实了我们的实证结果对于捕捉旧新闻的替代方法是稳健的。例如, 使用双词 (单词对) 而不是单词时, 措施几乎不变。并且对于基于余弦相似度量度的替代构造具有鲁棒性 (科恩等人)。 (2020) ; Fedyk (2022) 比较了文章中单词的完整向量旧内容测量分布已在图 1 的面板 i 中呈现。3. 很大一部分文章, 近 40%, 几乎全部 (90% 或更多) 由

11 对于上下文, 以下是 AAPL 的一些示例标题, 以及它们的相对得分: "Apple 在 3/17 宣布推出新 iPad 的活动" (95 % 相关性); "Android 在美国的发展智能手机市场 shr 至 50.1% "(70% 相关性); "Jcpenney 在标准普尔的新股晚上下跌至 bb "(50% 相关性)。