




图3. 文章级别的文本新颖度测量分布。面板1显示了旧测量的直方图，面板2显示了 ClosestNeighbor 测量的分布。

之前关于同一个 BLM 的新闻。样本中另外30%均匀分布在60-90%的先前覆盖范围。剩余部分至少有40%的内容。很少有文章少于10%的旧内容，因为即使是关于同一安全主题的无关新闻文章，也很可能会共享共同的单词。我们定义旧新闻（用二进制指标OldNews（s）表示）为至少有60%的内容被最近关于同一公司的文章所涵盖。在第5.5节中，曾特在检查考虑了以下替代方案：(i)查看过去五天或十天的类似文章，而不是三天；(ii)查找最近的十篇文章，而不是五篇；(iii)改变旧新闻的阈值。我们还表明，我们的结果对于使用连续的旧内容指标而不是二进制的指示变量是稳健的。

$S_i = 1 \text{ s}' i(s)$ ，同样标记与

这是什么？。这一行捕捉到了(i)中给出的旧信息的衡量标准：s内容的百分之几在前五篇最相似的文章中至少出现过一次。在两个面板中，旧的度量值为90%。然而，这两个情况是非常不同的。图4的上部面板表明了一个重复：s几乎是一个精确的拷贝 $s'1(s)$ ，用阴影强调。相反，在底部面板中，没有一篇以前的文章能够捕捉s的50%以上内容，而是s是由 $s'1(s)$ 重新组合而成

and $s'2(s)$ (其与s的交集也被用实践阴影突出显示)我们通过外观来区分再版和重组在每篇文章的内容被其最近的前一个邻居 $s'1(s)$ 跨越的程度上：

3.2. 重印和重组

我们使用文本分析来区分Bloomberg数据中的两种旧新闻类型：单篇以前文章的重印和将来自两个或多个先前来源的信息组合在一起的两组合。图4展示了我们的方法。这个图的每个面板都显示了一篇新闻文章（用深灰色表示），以及在前5篇最接近的文章 $s'1(s)$ 中已经存在的内容， $s'5(s)$

$$\text{closestneighbor}(s) = \max s'1[s \cap \{s\} \parallel] = ||s \cap s'1(s)|| / ||s|| \quad (2)$$

Closest Neighbor measure 的分布显示在图3的面板2中。有大量的 articles 几乎所有的单词都出现在 sin - gle 最近的邻居（捕获精确的转载），并且有很大一部分文章的大约一半的单词出现在单个最近的邻居（潜在的 recombi - nations）中。

（以实心或阴影灰色标记）。底行显示