




图4. 两篇新闻文章，都是90%的旧新闻，但展示的是不同类型的旧新闻。Panel 1包含了一个重印示例：文章s，其中90%的内容由最近的邻居s1 (s) 覆盖。Panel 2提供了一个重组的例子：文章s也是90%旧的，但是它从先前的两篇文章s1 (s) 和s2 (s) 中重新组合信息。




图5. 文章分类为新闻报道、两版或重组。

我们对每篇文章进行分类，分为两步：首先查看其整体旧信息水平，然后考虑其旧信息被单个最近邻居所覆盖的程度。分类过程如图5所示。首先，如果一篇文章的文本至少有60%的内容已经被以前的文章所涵盖，那么就可以将其归类为旧闻

与以前关于同一主题的RM的文章最接近。接下来，对于旧新闻类别中的每篇文章，我们考虑该文章的旧内容被单个最近邻居所覆盖的比例。如果这个比例高于80%，那么我们把这篇文章归类为转载（用Reprint(s)这个指标变量表示）；如果这个比例低于80%，那么我们归类为原创