

MLink: 连接黑盒模型进行协作多模态推理

穆源, 兰张, 谢扬李

发送电子邮件
至"universityofscienceandtechnologyofchinaym0813@mail.ustc.edu.cn", "zhanglan@ustc.edu.cn"或"xiangyangli@ustc.edu.cn".

抽象

模型推理的成本效率对现实世界的机器学习 (ML) 应用至关重要, 尤其是在对延迟敏感的任务和资源受限的设备上。一个典型的困境是: 为了提供复杂的智能服务 (如智能城市), 我们需要多模态ML模型的推理结果, 但成本预算 (如GPU内存) 不足以运行所有它们。在这项工作中, 我们研究了黑色盒式ML模型之间的底层关系, 并提出了一个新的学习任务: 模型链接。模型链接旨在通过学习映射 (称为模型链接) 来桥接不同黑色盒模型的输出空间, 从而实现不同模型之间的知识传递。根据模型链接, 我们开发了一个名为MLink的调度算法, MLink通过协作多模型推理启用了模型链接, MLink可以提高获得的推理结果的准确性, 在GPU内存预算下实现了667%的推理计算节省, 同时保留了94%的推理准确性, 这超过了基于多任务学习、深度强化学习调度程序和帧过滤基线的推理结果。

Blum et al. 2020; Bai et al. 2020) techniques attempt to eliminate parameters and connections not related to the inference accuracy; Inference reusing (Guo et al. 2018; Ning, Guan, and Shen 2019) approaches aim to avoid the same or similar computations; Source filtering (Li et al. 2020) methods try to transmit only necessary input data to backend ML models; Adaptive configuration (Jiang et al. 2018) and multi-model scheduling (Yuan et al. 2020a) were proposed to make inference workloads adaptive to the dynamics of input content. We summarize them as answers to an interesting question: How to obtain as accurate inference results as possible without the exact execution of ML models? From this perspective, multi-task learning and model compression generates a lighter model for the same inference task(s) by pruning the original model(s); Inference reusing and source filtering techniques reuse previous inference results as the predicted results through analyzing the correlation between inputs.基于观察到的一个问题: 对于某些输入数据, 昂贵和便宜的模型在准确性上类似, 自适应配置分析输入动态并预测昂贵模型的推理结果, 通过执行便宜的模型来预测不必要的推理结果自适应多模型调度通过执行便宜的模型的输出作为提示信息来预测空白的推理结果我们是从新颖的角度来解决这个问题的: 链接黑盒模型我们被激励: 即使输入模态、学习任务 and 架构等不同的ML模型之间存在差异, 它们也可以共享知识, 因为ML模型容易“过拟合” (Song and Shmatikov 2020), 不同的模型的输出之间存在语义相关性 (Tan et al 2018) 如果我们能够有效地在ML模型之间建立知识层面的联系, 那么我们可以直接根据执行模型的输出预测未完成模型的推理结果, 如果预测成本低, 这有望在有限的预算内提高所有模型的推理结果的准确性, 与原始工作流程相比, 可以获得更多的未执行模型的结果 (通过执行未完成的模型) 这需要解决两个主要挑战: (1) 如何在大规模和高度不同的ML模型之间建立知识层面的联系? 在实践中, 部署的ML模型可能有不同的架构和输入模式, 并且它们可以通过不同的编程语言和ML框架来开发, 不同模型之间的差异可能导致它们的输出存在很大的差异, 这会使得在模型之间建立知识层面的联系变得困难, 更不用说将知识传递给其他模型了。

multi-model inference workloads are increasingly prevalent, such as those of smart speaker assistants (Bentley et al, 2018), smart cities (Duan et al, 2018), drone-based video monitoring (Dil-shad et al, 2020), and multi-modal autonomous driving (Feng et al, 2020).2020), etc. Besides the accuracy of the trained models, costs in the inference phase can become the bottleneck to the quality of services, especially for delay-sensitive tasks and resource-limited devices. Towards cost-efficient inference, existing work has explored various perspectives to achieve the resource-performance trade-offs. Multi-task learning and zipping (He, Zhou, and Thiele 2018; Sanh, Wolf, and Ruder 2019; Crawshaw 2020; Zhang and Yang 2021) can reduce the computing overheads by sharing neurons among different tasks. Model compression (Hinton, Vinyals, and Dean 2015; Liu et al 2018; Gold-

兰张 是本文的通讯作者 © 2022 年, 人工智能促进协会 (www.aail.org) All rights reserved