


在本节中，我们将讨论链接黑盒模型的动机，并介绍模型链接的理论分析，架构设计，集成和训练方法。

Motivational Study

当训练不同任务的机器学习模型时，它们学习的理想表示应该是独立的和不纠缠的（Hjelm et al. 2019），即每个模型只学习那些只覆盖其目标任务的语义。然而，由于数据和模型的不匹配的复杂性，机器学习过程容易过度学习（Song and Shmatikov 2020），这意味着非预期的语义被编码在学习的表示中。此外，不同任务和不同模型的输出之间存在语义相关性，这可能会导致模型关注相同的内容，例如图像中的相同区域。例如，在图 1a 中，基于 g - cam（selvaraju 等人 2020），我们绘制了 yolo - v3（redmon 和 farhadi 2018）对象检测器和 resnet50（he 等人 2016）的注意热图在相同的图像上进行场景分类，并且它们的关注区域有多个重叠区域。我们对注意力热图的重叠率与模型链接性能之间的相关性进行了实验。例如，从场景分类模型到目标检测模型，如图 3 所示。如图 1b 所示，模型链接的准确性显然与重叠率（ $\text{Map}_{\text{target}} / \text{Map}_{\text{target}} / \text{Map}_{\text{target}}$ ）相关。在一定程度上表明，通过模型链接学习的相关性与语义注意相似。输出之间的过度学习特征和潜在的语义相关关系使得从相同或对齐的输入空间到不同输出空间的映射可以传递（Tan 等人 2018）。

Black-Box Output vs. Intermediate Representati

一个关键的设计原则是，我们只使用源模型的黑盒输出来进行模型链接。现有工作表明，通过微调最后几层（Guo 等人，2019），中间表示可以用于预测其他不同的任务。然而，在实际应用中，我们经常需要处理已部署的模型，这在此模型只提供一个黑盒推理 API。与中间表示相比，下游黑盒输出对一般学习任务的表示能力较弱。但是最近的工作（Yuan 等人，2020a）表明，给定相同（或对齐）的输入，执行模型的输出是调度未执行模型的非常有效的提示。见解是，具有相同输入的多个任务之间的黑盒输出的相关性比中间特征更明确，甚至更强。实验结果还表明，使用相同数量的训练数据，黑盒模型链接比知识蒸馏方法（见图 2）和多任务学习方法（见表 4）具有更高的准确性。考虑到更好的实用性和令人满意的准确性，我们选择黑盒输出而不是中间表示来链接 ML 模型。



(a) Attention heatmaps of Object and Scene models. (b) Scene-to-Object MLink accuracy vs. attention overlap

图 1：模型间语义相关性

Sample Complexity Analysis

令 $f \in F$ 表示特定任务的参数， h 表示跨任务的共享参数。已经证明，当 h 的训练数据丰富时，要在新任务上实现有界预测误差，只需要 $C(F)$ 样本复杂性（Tripuraneni, Jordan 和 Jin 2020），其中 $C(\cdot)$ 是假设族的复杂性。从源模型 $f_i \in F_i$ 学习模型链接 $g_{ij} \in G \in F_i$ 到 $\text{target} f_j \in F_j$ 构成了一个复合学习模型 $g_{ij} \in f_i$ 。模型链接的轻量级设计可以使 $C(G) < C(F_j)$ 成立。因此，应用上述结果，与从头开始学习目标模型的 $C(F_j)$ 复杂度相比，建模可以显著降低样本复杂度 $\text{to } C(G)$ 。实验也证实了这一结果：有效的模型链接可以通过非常少量（例如 1 %）的训练样本来学习（见图 2）。

Model Link Architecture

模型链接在黑盒模型的输出空间之间映射，因此输出格式决定了体系结构。我们将输出格式分类为固定长度向量和可变长度序列。这两种类型的输出可以覆盖大多数 ML 模型。根据类似学习任务的最佳实践，我们提出了四种类型的模型链接结构。Vec - to - Vec：模型链接从矢量输出源映射到矢量输出目标。我们将 ReLU 激活的多层感知（MLP）用于 vec 到 vec 模型链接。Seq - to - Vec：模型链接从序列输出源映射到向量输出目标。我们首先使用嵌入层，它执行矩阵乘法将序列转换为固定大小的嵌入。然后，我们使用一个 LSTM（Hochreiter 和 Schmidhuber 1997）层，然后使用 MLP 生成向量输出。Vec - to - Seq：模型链接从向量输出源映射到序列输出目标。我们采用编码器 - 解码器框架，其中 MLP 作为编码器，解码器由嵌入层，LSTM layer，关注层（Bahdanau, Cho 和 Bengio 2015）和全连接层组成。seq - to - seq：模型链接从序列输出源映射到序列输出目标。我们采用序列到序列框架（Sutskever, Vinyals 和 Le 2014），其中嵌入层后跟 LSTM 层作为编码器，解码器与 vec 到 seq 模型链接中的解码器相同。