

输出激活函数由目标模型的学习任务确定。Softmax 用于单标签分类，sigmoid 用于多标签分类和序列预测。线性激活与回归和本地化任务一起工作。在我们的实现中，隐藏单元的默认数量是输出维度长度的两倍，这在经验上实现了有效性和效率之间的良好权衡。

Ensemble of Multi-Source Links

多源模型链接的集合有可能提高预测性能（Shen，He 和 Xue2019），模态表示能力可能是有益的。对于目标模型 f_j ，给定一组源 A ，我们将 g_{ij} 的输出乘以可训练权重 w_i ，其中 $f_i \in A$ 。然后根据 f_j 的学习任务来激励加权预测。 $h_{A,j}$ 的学习权重可用于集成来自任何子集的源的模型链接，即， $h_{A^1,j}, h_{A^2,j}, \dots, h_{A^k,j}$ 。

Training

经典的知识提炼（Hinton，Vinyals 和 Dean2015）表明，“软标签”监督对于训练“学生”模型更好，因为“老师”模型的输出通过不同班级之间的关系扩大了硬标签空间。我们的实验结果表明，这种经验在建议的模型链接设置中仍然成立。为了训练模型链接和集成模型，我们从相同或对齐的输入上的 k 个模型中收集 n 个推理结果 $\{y_{ij}\}_{k,j=1}^n$ ， $n_i = 1$ 。分别给定 f_i, f_j 作为源和目标，训练模型链接 g_{ij} 的目标是 $\min_{g_{ij}} \sum_{i=1}^n L_j(g_{ij}(y_{li}), y_{lj})$ ，其中损失函数 L_j 取决于目标模型 f_j 的学习任务。分别给定 A, f_j 作为源和目标的集合，训练集成模型 h_A ， $\min_{h_A} \sum_{i=1}^n L_j(h_A(y_{li}), y_{lj})$ ， $f_i \in A$ ， y_{li} 的目标。模型链接和集成模型都是通过梯度下降法优化的。请注意，如果 A 只有一个元素 f_i ，则系综简单地适合作为身份层，并且 $h_A, j = g_{ij} f_i$ 。

定义 $f(a) = 1 \mid f \mid (f_i \in a) + f_j \in f(a, f_j)$ ，再激活一个模型 f_i 的增益为 $(a, f_i) = f(a \cup \{f_i\}) - f(a)$ 。假设将模型链接的源添加到集成模型中不会降低性能： $p(a \cup \{f_i\}, f_j) \geq p(a, f_j)$ 。这在经验上是正确的（Zhou 2012）。则 $(a, f_i) \geq 0$ 。在我们的实验中，我们观察到两个典型的情况：（1）优势。集成模型的性能约等于模型链接的最佳性能源。让 $f_i = \arg\max_{f_i \in A} p(g_{ij})$ ，去注意具有最大性能的源。我们观察到 $p(h_A, f_j) \approx p(g_{ij}, f_j)$ ，即最佳源支配性能。（2）互助。多源模型链接集成的性能优于任何单个源。 $f_i \in A, p(h_A, f_j) > p(g_{ij})$ ，即模型链接的来源相互协助。在这种情况下，如果 f_j 与 A^2, A^1 中的模型更好地合作，则 f_j 对 A^2 的增益可能大于其对 A^1 的增益。

Algorithm 1: Collaborative Multi-model Inference

Input: model set F , cost budget B

- 1 For every $f_i, f_j \in F, i \neq j$, train model links g_{ij} ;
- 2 For every $f_j \in F$, train ensemble model $h_{A_j,j}$, where $A_j = F \setminus \{f_j\}$;
- 3 **for each period do**
- 4 Profiling activation probability of $f_i \in F$;
- 5 Greedy select $A \leftarrow A \cup \{argmax_{f_i \in F \setminus A} (P_i)\}$ until reach the cost budget B ;
- 6 Given incoming input x , for $f_i \in F$:
- 7 **if** $f_i \in A$ **then:** $y_i \leftarrow f_i(x)$;
- 8 **else:** $y_i \leftarrow h_{A,i}(\{y_j\}_{f_j \in A})$.

激活概率。求解方程。（1）是 NP 难的，并且（ $1 - e^{-1}$ ）近似算法（Sviridenko 2004）需要部分枚举，并且需要对目标函数进行 $O(n^5)$ 计算。优化不是一次性的过程，应该在线执行以适应推理系统的动态。因此，我们设计了一个启发式度量的制造概率，其计算仅取决于模型链接的性能，而不是集成模型。给定模型 f_i ，激活概率考虑三个因素：（1）模型链接从 f_i 到所有其他链接的平均性能，表示为 $P1_i = \frac{1}{|F|} \sum_{j \in F} p(g_{ij})$ ；（2）以 f_i 为目标模型链接的平均性能，表示为 $P2_i = \frac{1}{|F|} \sum_{j \in F} p(g_{ji})$ ；（3） f_i 的成本，即 $c(f_i)$ 。然后，我们将激活概率设计为 $P_i = \frac{1}{w} (P1_i + P2_i - c(f_i))$ ，其中权重 w 可以通过以下归一化确定。通过将范围正则化为 0 到 1，我们有 $(1 + \frac{1}{w \min_i (c(f_i))}) / (1 + \frac{1}{w \min_i (c(f_i))}) = 1$ ，即 $w = 2 / \min_i (c(f_i))$ 。在选择 ML model 时，可以将此激活概率重新标记为与目标函数的增益正相关的系数。定期重新-selection. 由于内容动态，激活模型的最佳子集可能会随时间变化。但是适应这种动态会带来额外的装载和卸载 ML 模型的开销。因此，我们建议定期重新选择激活的模型。在每个周期的开始，我们使用一小部分（例如 1%）的数据来分析模型链接的预测性能。然后，我们更新 ML 模型的激活概率，并重新选择要在当前期间加载的模型。通过合理设置周期长度和用于分析的数据比例，我们可以将加载 / 卸载 ML 模型的开销分摊到可忽略的水平。算法。图 1 显示了将 MLink 与多模型推理工作负载集成的工作流程。最初，我们训练成对模型链接和集成模型。在每个周期中，我们首先通过在数据上运行所有模型进行分析来计算激活概率。然后我们在成本预算下选择贪婪的 $w.r.t.$ 激活概率。在服务阶段，激活的模型进行精确的推理，而其他模型的输出将由激活源的模型链接集合预测。