

Task Class	ML Model	Input Modality	Output Format	Metric
Single-Label Classification	Gender Classification (Kumar 2021)	Audio	2-D Softmax Labels	Acc.
Multi-Label Classification	Action Classification (Tran et al. 2015)	Video	12-D Sigmoid Labels	mAP
Localization	Face Detection (Serengil and Ozpinar 2020)	Image	4-D Bounding Box	IoU
	Person Detection (Redmon and Farhadi 2018)	Image		
Regression	Age Prediction (Levi and Hassner 2015)	Image	1-D Scalar	MAE
Sequence Generation	Image Captioning (Wang 2021)	Image	Variable-Length Text	WER
	Speech Recognition (Mozilla 2021)	Audio		

Table 1: Summary of ML models used on Hollywood2 dataset.

Evaluation

Implementation and Experiment Setup

我们基于 TensorFlow 2.0 ((TensorFlow 2021)) 在 Python 中实现了我们的设计，作为推理系统 1 的可插拔中间件。我们测试了使用 TensorFlow ((TensorFlow 2021))，PyTorch ((PyTorch 2021)) 和 MindSpore ((MindSpore 2021)) 实现的程序上的集成，只需几十行代码修改，这显示了 MLink 的易用性。我们在多模态数据集和两个真实世界的视频分析系统上评估了我们的设计。多模态数据集和 ML 模型。我们使用了 hollywood2 视频数据集 (marszalek, laptev 和 schmid2009)，为了获得多模态模型的对齐输入，我们选择了第 30 帧并从每个视频中提取了音频数据。我们部署了七个预训练的 ML 模型，涵盖了五类学习任务：单标签和多标签分类，对象定位，回归和序列生成。它们有不同的模型架构、输入模式和输出格式。为了评估模型链接的性能，我们使用了特定于任务的指标，包括准确性，平均平均精度 (mAP)，边界框的交叉并集 (IoU)，平均绝对误差 (MAE) 和单词错误率 (WER)，表 1 总结了这些 ML 模型的信息。智能建筑和城市交通监控系统。我们在两个真实的视频分析系统上评估了 MLink。1) 智能建筑。为了支持包括自动空调和照明，异常事件监视和财产安全在内的应用程序，采用了三种 ML 模型：基于 OpenPose (Cao 等人，2019 年) 的人员计数，ResNet50 (He 等人，2016 年) 基于动作分类 (Olafenwa 2021a) 和基于 YOLOV3 (Redmon 和 Farhadi2018) 的对象计数。我们从所有 58 个摄像机 (每分钟 1 帧)，收集了两天 (一个工作日和一个周末) 的视频帧。我们使用带有一个 nvidia 2080ti gpu 的边缘服务器。(2) 交通监控。在具有 20,000 多个摄像头的城市规模视频分析平台上，部署了三种 AI 模型用于交通监控：基于开放姿势 (Cao 等人，2019 年) 的人员计数，基于 ResNet50 (Heet 等人，2016 年) 的交通状况分类 (Olafenwa2021b) 和基于 YOLOV3 (Redmon 和 Farhadi 2018) 的车辆计数。我们在路段选择了 10 个摄像头，并收集了两天 (一个工作日和一个周末) 的帧 (1 FPS)。我们使用了五台服务器，每台都有四台 nvidia t4 gpu。

基线。我们引入了朴素的独立推论和三种强大的替代资源绩效权衡方法作为基线。(1) 独立：独立运行模型。(2) MTL：我们采用多任务学习架构 (Crawshaw 2020) 该架构由所有任务和特定任务输出分支共享的全局特征提取器组成。我们使用 ResNet50 (He 等人，2016) 来实现特征提取器和完全连接的层，用于特定于任务的输出。我们使用在 ImageNet (Deng 等人，2009) 上预先训练的权重初始化 ResNet50 功能，并在智能建筑 / 交通监控测试台上连接三个输出分支，用于人员计数 / 动作 / 交通分类和对象 / 车辆计数任务。MTL 模型在相应模型的精确参考结果的监督下进行训练。(3) 简化为 (Lietal.2020)：一种帧滤波方法。对于每个模型，Reducto 首先计算连续帧的特征差异。如果特征差异低于阈值，它将过滤掉当前帧并重新使用最新的推理输出。我们测试了 Reducto 中提出的四种类型的低级功能，并选择了性能最好的一种。(4) DRLS (基于深度强化学习的调度器) (Yuan 等人，2020a)：一种多模型调度方法。DRLS 训练一个深度强化学习代理，根据对已执行模型输出的观察，预测下一个要在给定数据上执行的模型。

Black-Box Model Linking

对训练数据大小的敏感性。Hollywood2 数据集中的原始训练和测试片段分别包含 823 个视频剪辑 (约 48 %) 和 884 个视频剪辑。为了测试与不同大小的训练数据链接的模型的性能，我们进一步随机抽样了四个子集的训练数据，分别占总数据集的 1 %，5 %，10 %，20 %)。我们使用 RMSprop (Tieleman 和 Hinton 2012) 优化器和相同的超参数 (0.01 学习率，100 个时期，32 批大小)，训练了成对模型链接。为了进行公平的比较，我们对一些目标模型 (动作，年龄，性别) 采用了知识提炼 (Hinton，Vinyals 和 Dean 2015) 方法。学生模型具有两个卷积层。我们重复了三次实验，并报告了性能的平均值和标准变化。如图 2 所示，使用所有训练数据，Caption - to - Action 模型链接可以实现 31.7 % 的 mAP。两个检测模型之间的模型链接，面对面 and 面对面模型链接，分别达到 59% 和 32% IoU。即使训练样本非常有限，1%，一些模型链接也能达到很高的 Per -