




Figure 2: Performance of model links from different source models on four targets. KD-Student: student model trained via knowledge distillation on the target model.

Source	Action	Age	Face	Gender
IoU (%)	39.4 (± 0.1)	38.9 (± 0.1)	58.5 (± 1.3)	39.0 (± 0.1)
Corr.	0.123	0.042	0.244	-0.053

表 2：以 Personmodel 和 Pearson 相关性为目标的模型链接的 IoU 得分。

业绩。从面部到性别的模型链接达到 92.1% 的准确率。对于模型链接，性别 - 年龄模型实现了 3.0 mae。与在目标模型上通过知识提炼训练的学生模型相比，模型链接具有更高的预测性能，尤其是在训练数据量较小时。但是对于语音识别和视频字幕模型，无法有效地构建针对它们的模型链接，并且具有大约一个 WER 分数。讨论。我们计算了训练分割上不同模型的推理输出之间的皮尔逊相关系数。对于单标签和多标签分类模型，我们使用置信度最高的索引作为标签。对于本地化模型，我们检查边界框是否为空，并指定 0 或 1 作为标签。我们使用回归量作为标签，并跳过了两个序列生成模型。tab. 2 显示了针对人物模型的模型链接的结果，我们可以看到模型链接性能和 pearson 相关系数之间的正相关。模型链接集成。对于一个目标模型，我们从不同的源模型构建了多个模型链接。然后，我们使用所有源训练集成模型，使用与模型链接相同的优化器和相同的超参数。表 3 显示了五个目标模型的结果，模型链接和集成模型都使用




Figure 3: MLink's overheads on servers and mobile phones.

所有训练样本 (48% 的比率)。模型链接集成优于每一个源模型。我们可以看到有两种典型的情况：支配和互助。对于动作，人脸，人物目标，字幕，人物，人脸源分别主导合奏性能。但是对于年龄和性别目标，源模型相互帮助，并通过集成实现性能提高。

Analytics with Model Link

我们在智能建筑系统中的 58 个摄像机的 48 小时视频和城市交通监控平台上的 10 个摄像机的 48 小时视频上测试 MLink。我们利用前 10% 的时间数据来训练模型链接和集成。我们将周期长度设置为一小时，并使用初始 1% 的数据来激活概率。对于计数模型，通过检查预测数的绝对误差是否小于 0.5 来计算输出精度。每个机器学习模型的时间成本是由训练数据描述的平均离线推断时间。在智能构建系统中，动作 / 人 / 对象模型每帧成本为 30 / 44 / 60ms。在交通监控系统中，交通 / 人 / 车辆模型每帧成本为 55 / 66 / 70 ms。每个 ML 模型的 GPU 内存成本是我们的峰值年龄：人员计数为 4.6 GB，动作 / 交通分类为 1.5 GB，对象 / 车辆计数为 3.7 GB。将预算 B 设置为分配给 ML 模型的最大 GPU 内存，以评估 MLink 如何提高多模型推理的资源效率。我们平等对待每个 ML 模型的输出精度，并报告其平均输出精度。在 GPU 内存预算下，基线“独立”简单地选择具有最小平均时间成本的模型。我们重复了三次调度实验，并在表 4 中报告了结果。由于标准偏差很小 (< 0.1)，为了简单起见，我们没有给出它们。在这两个系统中，“mlink”在输出精度方面都优于替代方案。与“独立”相比，在智能建筑系统中，MLink 节省了 66.7% 的推理效率，同时保持了 94.1% 的输出精度。MLink 的开销。我们在四个不同的设备（云服务器，边缘服务器，笔记本电脑和移动电话）上部署了 MLink，并测试了其延迟和内存占用。如图 3 所示，MLink 仅引入可忽略的额外开销。