

Target \ Source	Action	Age	Caption	Face	Gender	Person	Speech	Ensemble
Action mAP(%)	-	12.8($\pm$ 1.3)	29.7($\pm$1.4)	10.1($\pm$ 1.3)	9.3($\pm$ 0.3)	9.9($\pm$ 1.2)	8.5($\pm$ 3.1)	30.8($\pm$ 1.1)
Face IoU(%)	11($\pm$ 1.3)	11.2($\pm$ 1.0)	0 ($\pm$ 0)	-	10.3($\pm$ 0.9)	31.9($\pm$0.3)	0 ($\pm$ 0)	32.2($\pm$ 0.2)
Person IoU(%)	39.4($\pm$ 0.1)	38.9($\pm$ 0.1)	0($\pm$ 0)	58.5($\pm$1.3)	39.0($\pm$ 0.1)	-	0($\pm$ 0)	59.2($\pm$ 1.2)
Age MAE	3.04($\pm$ 0.01)	-	3.02($\pm$ 0.01)	3.07($\pm$ 0.02)	3.0($\pm$ 0.01)	3.03($\pm$ 0.01)	3.0($\pm$ 0.01)	2.98($\pm$ 0)
Gender Acc.(%)	92($\pm$ 0.1)	92.1($\pm$ 0.2)	92($\pm$ 0.1)	92.1($\pm$ 0.1)	-	92($\pm$ 0.1)	92($\pm$ 0.1)	92.3($\pm$ 0)

表 3: 模型链接集成中的优势和互助案例。列标题是源模型，行标题是目标模型。主要来源的表现是粗体。

Method	Building (5/9GB Mem.)		City (5/9GB Mem.)	
	Acc. (%)	Time (ms)	Acc. (%)	Time (ms)
Standalone	33.3/66.7	30/74	33.3/66.7	55/121
MTL	53.3	32.8	61.3	32.5
DRLS	45.7/81.3	58.7/107	39.5/77.6	102/188
Reducto	91.8/96.9	45.7/89	84.1/95.3	64/127
<i>MLink</i>	94.1/97.9	39.3/84	94/97.4	62/125

表 4：在两个视频分析系统上比较 MLink，MTL，Reducto，DRLS 和 Standalone 方法。

Related Work

多任务学习和压缩。优化多个独立 ml 模型的一个简单方法是多任务学习 (sanh, wolf 和 ruder 2019; zhang 和 yang2021; crawshaw 2020) 和压缩 (he, zhou 和 thiele2018)。通过在不同任务之间共享相同的骨干神经网络，在相同的成本预算下，独立模型更丰富的推理结果。但是，多任务学习方法缺乏灵活性和可伸缩性，即，我们需要逐案定制多任务解决方案，并在任务集更改后重新设计。相反，尽管不同的黑盒 ML 模型之间存在参数冗余，但 MLink 方法可以灵活扩展。实验表明，当给定少量训练数据时，模型链接的准确性更高。知识升华。遵循最近调查中的分类法 (Gou 等人, 2021 年)，知识提炼有三个主要的知识来源：(1) 响应 (Ba 和 Caruana, 2014; Hinton, Vinyals 和 Dean 2015)： “老师” 模型的输出；(2) 特征 (Chen 等人, 2021 年)：中间特征图；(3) 关系 (Passalis, tzelepi 和 tefas 2020)：要素地图的关系。提出了相互提炼 (Zhang 等人, 2018 年; Yao 和 Sun, 2020 年)，以融合一个 “学生” 模型，并让它们相互学习。提出了跨任务蒸馏 (Ye, Lu 和 Zhan 2020)，以通过为另一项任务预先训练的 “老师” 模型来训练 “学生” 模型。模型链接是知识提炼的补充，即可以在提炼的 “学生” 模型之间建立模型链接。冗余过滤。过滤冗余计算或通信是实现成本效益推理的一种有前途的方法。元等人。(Yuan et al. 2020a) proposed a re -

基于强制学习的调度程序，用于多模型数据 la - belling 任务。它利用已执行模型的输出作为提示信息来调度其余模型。Re - ducto (Li 等人, 2020) 通过设置连续帧之间的特征差异来过滤视频帧。DNNs 感知视频流 (Xie 和 Kim 2019; Du 等人 2020) 被提出用来压缩与推理准确性不太相关的像素，以实现通信高效的推理。Foggycache (Guo 等人, 2018 年)通过自适应哈希输入值重用缓存的推理结果。我们提出的 MLinkscheduler 以一种新颖且更重定向的方式优化了成本效率：通过执行的模型的输出来预测未执行的 ML 模型的推理结果。

Conclusion and Discussion

在这项工作中，我们建议链接黑盒 ML 模型，并提出模型链接的设计和协作多模型推理算法。综合评估显示了与其他替代方法相比，黑盒模型链接的有效性和 MLink 的优越性。我们将局限性和未来的工作总结如下：(1) 当源模型和 tar - get 模型之间的语义相关性较低时，模型链接的输出准确性较差。(2) 当加入的模型数量非常大时，成对模型链接将变得不切实际。因此，我们将研究如何明智地选择模型以在未来建立模型链接。(3) 由于参数数量少，因此训练成本很小 (例如，具有 100 维输入和输出长度的 vec 到 vec 模型链接使用 1k 个样本训练 100 个 epoch 的成本为 12.9 s)，因此用于更新 MLink 的定期重新训练策略是可行的。我们将研究在线学习和主动学习机制，以进一步提高 MLink 对输入动态的适应性并减少更新的开销。

Acknowledgements

本研究由中国国家重点研发计划 2021YFB2900103，中国国家重点研发计划 2018YFB0803400，中国自然科学基金 61822209 号，62132018 号，61932016 号，61625205 号，中国科学院自然科学基金重点研究计划资助。编号 QYZDY - SSCA00A1 - JSC2。