

• 理论研究 •

# 基于Rule-Faster-RCNN的多语科技论文 PDF文档结构框架元素解析

何彦青<sup>1</sup>, 陈光云<sup>2</sup>, 兰 天<sup>1</sup>, 李 岩<sup>1</sup>, 郭航程<sup>1</sup>

(1. 中国科学技术信息研究所 情报理论与方法研究中心, 北京, 100038;

2. 云南锡业集团(控股)有限责任公司 研发中心, 云南 昆明, 650000)

**摘 要:**【目的/意义】PDF文档能够如实地保存原文档的内容和外观,但也给文档的解析带来了很大的困难。为了更为全面、自动地挖掘多语科技论文的文本信息,本文对多语论文PDF文档的有效解析和知识抽取方法进行了探究。【方法/过程】本文提出一种基于Rule-Faster-RCNN的多语科技论文PDF文档结构框架元素的解析方法,将科技论文全文的结构框架元素分为文本元素和图表元素,采用规则辅以Faster-RCNN深度学习方法分别进行提取,其中规则方法利用论文行文版式特点识别文字框架元素和图表元素,深度学习方法将图表识别看作目标检测构建Faster-RCNN网络来补充规则方法的不足。【结果/结论】经过实验验证了本文提出的PDF解析方法优于基准方法,成功地获取了科技论文的有效全文知识。【创新/局限】本文采用规则辅以深度学习方法更为精细地将多语科技论文的全文文档结构框架元素进行了提取,并验证了方法的有效性;然而限于PDF文档的复杂程度,表元素仅作为图片进行了提取,未能深入到表格内部的文本信息。

**关键词:**多语科技论文;PDF文档;结构框架元素;图表解析;Rule-Faster-RCNN

**中图分类号:**G254      **DOI:**10.13833/j.issn.1007-7634.2023.04.007

## 1 引 言

随着科技的快速发展和信息更新迭代的加快,全球产生的科技论文数量产生爆发式增长态势,同时呈现出多语种和大信息容量的特征。科技论文多数以PDF(便携文档格式, Portable Document Format)的文档格式进行存储。PDF文档在PostScript语言图像模型的基础上将文字、字型、格式、颜色及图形图像封装在一起,是Adobe公司开发的一种满足用户进行方便可靠并与平台无关的电子文档交换和阅读的文件格式<sup>[1]</sup>。PDF文档能够如实地保存原文档的内容和外观,但也给文档的解析带来了很大的困难。多语科技论文的信息服务通常只能利用论文的标题和摘要等元数据,无法更为有效地使用PDF文档内部的全文信息,从而降低了跨语言信息检索的准确度,影响了多语论文信息的传递效率,造成了信息资源的浪费。因此对多语科技论文的PDF文档进行有效解析并在全文上实施知识抽取有助于快速有效检索文档内容从而实现跨语言的知识服务与知识共享。

通常PDF文档解析只能从PDF文档中直接或间接地获取文档信息,文档信息忠实于PDF的原本版面样式,无法直接得到PDF文档中全文的结构框架元素,不利于更深入地进行知识抽取。已有的科技文本结构识别方法着重处理论文的局部,无法获取全文的整体信息。本文提出基于Rule-Faster-RCNN的多语科技论文PDF文档结构框架元素的解析方法,对多语科技论文的PDF文档进行特征分析,将论文全文的结构框架元素分为文本元素和图表元素,采用规则辅以深度学习方法分别进行提取,其中规则方法利用论文行文版式特点识别文字框架元素和图表元素,深度学习方法将图表识别看作目标检测任务构建Faster-RCNN网络来补充规则方法的不足。经过实验验证,基于Faster-RCNN的多语论文PDF文档结构框架元素的解析方法成功地获取了科技论文的文本和图表的文档结构框架元素等有效全文知识。

本文在第2章给出科技论文PDF的文档解析和信息提取的相关研究,第3章介绍科技论文的全文结构框架元素,第4章阐述基于Rule-Faster-RCNN的多语论文PDF结构框架元素解析方法,第5章展示实验过程和结果分析,最后在

收稿日期:2022-06-07

基金项目:中国科学技术信息研究所重点工作项目“面向短文本的俄汉双向机器翻译研究”(ZD2022-20);云南省稀贵金属材料基因工程(一期2020)“锡钨材料基因工程专用数据库平台建设及示范应用”。

作者简介:何彦青(1974-),女,河北石家庄人,博士,研究员,主要从事机器翻译和自然语言处理研究;陈光云(1968-),男,云南昆明人,硕士,高级工程师,主要从事信息化实施和项目管理研究,通信作者:13769306932@139.com;兰天(1995-),女,北京人,硕士,研究实习员,主要从事文本分析和情报学研究;李岩(1994-),男,河南新乡人,硕士,助理研究员,主要从事机器学习、文本分析、知识图谱构建研究;郭航程(1994-),男,河南项城人,硕士研究生,主要从事情报学和自然语言处理研究。

第6章进行总结。

## 2 相关研究

PDF格式在电子学术文献出版发行领域占有极其重要的地位,但因其复杂的技术规则,使得PDF无法被机器阅读,给针对学术文献的研究工作造成了诸多不便<sup>[2]</sup>。因此,如何解析PDF文档并获取其中的内容信息成为了国内外学界的一个研究热点。

PDF文档解析通常是将整篇PDF文档先转换成其他格式文档,在中间文档的基础上进一步获取其中的文本内容。这里的中间文档有文本TXT、XML、WORD、图像等格式,可以借助的化工具有Adobe Acrobat提供的编程接口Plug-in插件<sup>[3]</sup>、PDF2TXT<sup>[4]</sup>、PDF Text Stream<sup>[5]</sup>、PDF2HTML、pdf2gsdl、光学字符识别(OCR)等,一些应用软件也提供了PDF类库,例如java的PDFBox和iText、C++的XPDF、.Net的iTextSharp、PDFlib、Python的PDFMiner等<sup>[6-10]</sup>。OCR是一种较为成熟的图像文字识别方法,对于PDF文档的解析应用很广泛,可以识别带有地理位置信息的图纸,并对文字进行高精度的识别,包括生僻字在内。市面上常用的OCR软件有ABBYY、文通、云脉等,一些大型互联网公司如百度、搜狗、腾讯、阿里等也都开发了自己的OCR软件,改进OCR的相关算法或进一步提高OCR识别率的研究层出不穷。PDFMiner是一个Python的PDF解析器,可以获取PDF文档中文本的准确位置、字体、行数等信息,在PDF文档解析中也较为流行。目前学界已对PDF文档解析方法积累了大量研究成果,但由于“PDF文档在生成方式、遵从规范的版本、内容编排等方面略有差异”,学者们仍在提高算法的适用性方面不断进行探索。这些研究注重的是从PDF中提取文本信息,并未对文本信息进行更为精细地信息提取。本文在此基础上进一步提取了论文的全文框架元素,其中包含文本元素和图表元素,这些框架元素具有更知识化的属性。

除了文本内容,学者们特别对PDF文档中的图表、公式等部分信息也展开了针对性的专门研究。此类研究专注于PDF文档中的图形图像处理、内容的组织和标签内容等。2007年陈云榕等按照图像在页面中出现的顺序定位图像并依次提取图像压缩数据进而筛选获取PDF文件中的JPEG图像<sup>[11]</sup>;2010年张伯借助FoxitPDF开发工具包对PDF二进制码流进行解码,从内容流中分离出文本、图像等信息<sup>[12]</sup>;2013年焦娜设计规则实现PDF文档中数学公式检测方法<sup>[13]</sup>。2020年中国人民大学探究了一种从PDF文档中自动抽取表格数据和篇章结构的方法,从PDF文件中进行章节抽取,得到带有篇章结构的PDF文件;对章节剪裁后再进行表格抽取,将表格以html页面进行展示<sup>[14]</sup>。表格抽取的过程通常包括表格检测和表格结构还原,前者定位表格位置,后者重构表格的行和列,确定单元格数据之间的逻辑关系。从PDF中抽取表格有三种主要的思路<sup>[15]</sup>:①转换为HTML或XML等标记语言的Web格式,然后依赖标记构建模型识别

表格并抽取信息;②根据表格框线特征和像素特征实现表格区域检测定位,利用OCR技术提取表格数据;③借助PDF文件处理工具解码PDF流对象,依赖于PDF元数据中的文本特征和图形特征进行表格识别并提取。表格识别算法有最小二乘法拟合表格线算法<sup>[16]</sup>、基于直线交点交角的区域定位算法<sup>[17]</sup>、形态学操作提取表格框线并用Hough变换检测单元格内斜线的算法<sup>[18]</sup>、Faster-RCNN目标检测算法<sup>[19]</sup>。图片识别方法与表格识别算法类似,图片识别可以根据图片解析分辨率<sup>[20]</sup>、文本块的分布<sup>[21]</sup>来实施。西安理工大学利用Faster-RCNN解决PDF中复杂流程图的自动识别与解析<sup>[22]</sup>。上述工作着重于提取单语PDF文档中的图或者表,无法处理多语文档,本文针对多语PDF文档设计了规则结合深度学习的图表提取方法,提取内容除了图表信息之外还包含了图表的标题信息以及图表的文字说明等描述性信息。

对全文档内容进行精细抽取已有不少研究,目前集中在围绕文档逻辑结构展开学术文本结构功能的分析和识别<sup>[23]</sup>。此类方法可以分为规则方法、机器学习方法和深度学习<sup>[24]</sup>。规则方法从文档的布局和文本特征角度人工构建规则,实现对学术文本结构的划分。朱海军等针对科技论文的标题进行识别<sup>[25]</sup>,Kim实现对生物医学学术文献中标题、作者、单位和摘要的自动标注<sup>[26]</sup>。Constantin等人<sup>[27]</sup>着重PDF格式的学术文本的标题、作者、正文和参考文献等语义层面。机器学习的方法将学术文本结构识别转化为文本分类问题,采用条件随机场<sup>[28]</sup>、随机森林、支持向量机和朴素贝叶斯<sup>[29]</sup>等机器学习方法进行识别。Luong等人实现了学术文本标题、作者、摘要、图表、公式等逻辑结构的识别。Tuarob等人通过划分章节边界实现学术文本章节语义层次的自动识别。黄永等人重点研究了学术文本的章节标题<sup>[30]</sup>、章节内容<sup>[31]</sup>和段落内容<sup>[32]</sup>三个层次的结构功能识别。相较于机器学习方法,深度学习能够更加高效的自动完成数据表示和特征提取,通过低层的特征组合形成更加抽象的深层表示类型或特征,在文本分类器的学习性能明显更有优势。Rahman等人<sup>[33]</sup>将循环神经网络(Recurrent Neural Networks, RNN)引入到文档结构深度理解研究中。王佳敏等采用CNN、LSTM和CNN+LSTM模型对学术文本章节标题、章节段落和章节内容三个层次的文本进行结构功能识别,并设计投票方法探讨了不同层次和不同模型的融合效果。刘忠宝采用双向循环神经网络(Bidirectional Recurrent Neural Network, BiRNN)、双向长短时记忆网络(Bidirectional Long Short Term Memory, BiLSTM)、BiLSTM-CRF、BERT等深度学习模型对期刊论文进行摘要结构功能识别研究<sup>[34]</sup>。上述方法集中在单语PDF文档的处理,针对的内容多为局部信息,获取的文本结构功能较为单一。本文从多语论文的全文PDF文档出发,文档结构框架元素更为齐全和精细,包括文档名、元数据、正文内容、参考文献、致谢、图和表等。特别针对图和表元素提取其标题和文字表述信息。本文在设计了规则方法的基础上再运用深度学习方法进行补充,兼顾了信息抽取的高效率和准确性。

表1 论文文档结构框架元素

Table 1 Structure framework elements of paper documents

| 结构框架 | 框架元素 | 元素内容              | 内容属性                                                           |
|------|------|-------------------|----------------------------------------------------------------|
| 文档名  | 标题   | 标题内容              | 字体、字号区别于正文,一般不多于20个汉字或英文词,页面位置:开头,单独段落                         |
| 元数据  | 作者   | 姓名、机构             | 人名或机构名等命名实体,页面位置:标题下方,单独段落                                     |
|      | 摘要   | 摘要内容              | 有“摘要”或“Abstract”标识,页面位置:作者和关键词之间,单独段落                          |
|      | 关键词  | 关键词内容             | 有“关键词”或“keywords”标识,页面位置:摘要下方。单独段落                             |
|      | 分类号  | 中图分类号或DOI         | 有“分类号”或“DOI”标识,页面位置:关键词下方,单独段落                                 |
|      | 注释   | 作者及通讯作者简介、资助基金等内容 | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
| 正文   | 第1部分 | 段落列表              | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
|      | 第2部分 | 段落列表              | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
|      | 第3部分 | 段落列表              | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
|      | ……   | ……                | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
|      | 第n部分 | 段落句子列表            | 同层次章节标题字体、字号统一,其中的文本内容字体字号统一                                   |
| 参考文献 | 引文   | 引文列表              | 有“参考文献”或“References”标识,页面位置:正文下方,各引文单独成段落                      |
| 致谢   | 致谢   | 致谢内容              | 有“致谢”或“Acknowledge”标识,页面位置:一般在参考文献后面,单独段落                      |
| 图    | 图片   | 图标题、图片描述和图片       | 图通常嵌套在正文的文本内容中,包括图标题和图片,图标题位于图片的下方,单独成段落。图片描述为全文段落中关于图片的文本介绍   |
| 表    | 表格   | 表标题、表格描述和表格       | 表通常嵌套在正文的文本内容中,包括表标题和表格,表标题位于表格内容的下方,单独成段落。表格描述为全文段落中关于表格的文本介绍 |

3 科技论文结构框架元素

以期刊和学术会议论文为例,本文分析常见的科技论文结构后归纳得到全文的文档结构框架元素,见表1。一篇完整的科技论文应包括文档名、元数据、正文内容、参考文献、致谢、图和表等。其中文档名为论文的标题,简洁、恰当地反映了文章的特定内容,字体、字号区别于正文,一般不多于20个汉字或英文词,在论文的开头位置,单独成段落。元数据包括作者、摘要、关键词、分类号和注释等。作者是论文主题内容的构思、具体研究工作的执行及撰稿执笔等提供主要贡献的人员,为论文的法定权人和责任者。作者包括姓名及其所在机构或通讯地址,通常在标题下方,单独成段落。摘要提供文献内容梗概,简明确切地记述论文的主要内容,一般应包括目的、方法、结果、结论等语步信息,摘要字数一般是100~300字左右,在作者的下方,有“摘要”或“Abstract”标识,单独成段落。摘要后通常给出3~8个关键词,反映文献特征内容,便于文献检索。关键词有“关键词”或“keywords”的标识,位于摘要下方,单独成段落。分类号表示论文内容的类别,有“分类号”或“DOI”标识,位于关键词下方,单独成段落。注释通常在论文首页的页脚,表述作者简介、通讯作者、资助基金等,字体、字号区别于正文。正文内容通常从引言开始,表述研究的原因,介绍研究背景、研究意图及技术方案等。之后介绍相关研究和论文的研究方法,前者综述他人的研究方法,后者阐述该论文的观点、原理、方法及具

体达到预期目标的整个过程。正文可以分章节分层次来表述各部分具体内容,各个段落中附以表或图来帮助陈述。最后给出结论,强调论文的研究结果、创新性研究价值及对进一步深入研究本课题的建议。正文内容的同层次章节标题的字体、字号统一,其中的文本内容字体和字号统一。参考文献是论文中引用有关资料的出处,呈现为引文列表,各引文单独成段落。致谢陈述了所有合作者的劳动,有“致谢”或“Acknowledge”标识,一般在参考文献后面,单独成段落。图通常嵌套在正文的文本内容中,包括图标题和图片内容,图标题位于图片内容的下方,单独成段落。表通常嵌套在正文的文本内容中,包括表标题和表格内容,表标题位于表格内容的下方,单独成段落。

4 Rule-Faster-RCNN 方法

本文提出基于Rule-Faster-RCNN的多语PDF文档框架元素解析方法,其完整流程图如图1所示。该方法适用的科技文献为科技论文,同样可扩展到专利文献上。该方法首先进行文档清洗,进而分别实施文本元素的提取和图表元素的提取,得到文档结构框架元素。文档清洗步骤主要清洗文档标题。文档分类环节对PDF文档首先进行语种分类,再依据PDF类型二次分类。对分类后的PDF文档分别提取文本元素和图表元素,前者利用OCR解析和PDF转TXT工具进行精细的框架元素提取,后者采用规则结合目标检测的深度学习方法实施。具体的数据处理步骤见图2,下面分以

述之。



图1 文档结构框架元素提取流程图

Figure 1 Extraction flowchart of document structure frame elements

#### 4.1 文档清洗和分类

通常PDF文档存在多种维度的划分。从语种上,PDF文档涉及中文、英文、日语、俄语、韩语、法语、德语等多个语言,本文以中文和英文论文为例。从文献形式上,PDF文档可以划分为论文、专著、专利、科技报告等,本研究针对科技论文PDF。从页面布局上,PDF文档可以分为单栏、双栏、多栏。从PDF的转化来源来看,PDF又分为数字型标准PDF和非标准PDF,前者为word直接转化而成,后者为带浮层PDF或扫描PDF。针对不同的PDF文档,需要采取不同的解析方式从其中获取信息。

文档清洗步骤用来实施标题清洗,对过长的文档标题进行乱码去除和标题截短。文档分类包括语种分类、PDF类型分类和PDF内容分类。类型分类将PDF文档分为扫描类PDF(scan)、非扫描类PDF(digital)和无法识别(unrecognized)。使用pdfminer逐页分析PDF文档,定位每页文本出现的字符位置的方差和平均值,并获取两两相邻页面文本序列的相似度的均值和方差。根据PDF的每个页面文本位置和相邻页面文本相似度来确定该文件是否属于扫描类PDF,具体算法见图3。

无论是扫描类PDF,还是非扫描型PDF,语种分类都将其分为中文类PDF(ch)、英文类PDF(en)、其他类PDF(other)。通常中文论文的首页会有英文摘要,尾页会有英文参考文献,对语种分类形成干扰,因此去掉首页和末页后对剩下的页码进行语种识别。对于单页文档,直接将其分类为其他语种,实施人工分类;对于只有2页的文档,选取第2页进行语种识别。对于大于或等于3页的文档,选取去除首页和尾页的剩余页进行语种识别。使用PyPDF和pdfplumber读取PDF需要识别的所有页面的文字内容,并得到字符数最大的页码,通过langid工具对字符数最大的PDF页面进行语种识别,得到该PDF文档的语种分类结果。

#### 4.2 全文内容获取

为了获取论文的全文内容,扫描型PDF文档经过OCR处理,产生带有文字块、文字行、字符坐标等信息的以XML/JSON等常见存储形式表示的OCR结果。非扫描型PDF借用pdfminer和pdfplumber将页面的所有字符对象整理为字符串输出的TXT文件。

由于PDF文档有单栏、双栏和多栏排版,因此需要利用OCR结果中的文字块坐标信息并设计规则方法进行文字块重排序和段落换行处理,来获取全文的文本信息。

(1)文字块重排序。针对PDF每一页的OCR识别结果,根据页面的中线将页面划分为左右两部分。按照文字块和中线的相对位置将文字块分为左侧文字块、右侧文字块和横跨左右文字块。从上往下、从左往右依次查看每个文字块,碰到横跨左右文字块时,按照前面的左侧文字块、右侧文字块、横跨左右文字块的排序进行排列。依次执行这个操作,直到处理完整页的文字块止。此方法适用于单栏和双栏PDF,对于三栏的PDF,可以采用类似的方法进行处理,这里不再赘述。

(2)段落合并处理。OCR或者PDF转TXT得到的文本内容大都是按照PDF原始版面的文字位置进行存放,导致




图2 数据处理步骤

Figure 2 Data processing steps




图3 PDF类型分类算法

Figure 3 Classification algorithm of PDF type

```
<?xml version="1.0"?>
<document>
  <title_zh>基于用户的检索服务研究新进展综述</title_zh>
  <title_en>The Review of the New Development of the User-Based Retrieval Service</title_en>
  <author_zh>李广建1, 李芳2,3, 杨林2,4</author_zh>
  <author_en>Guangjian Li, Fang Li, Lin Yang</author_en>
  <affiliate_zh><1 北京大学信息管理系, 北京市 100871
    2 中国科学院国家科学图书馆, 北京市 100190
    3 昌吉学院, 新疆昌吉市, 831100
    4 中国科学院研究生院, 北京市 100049>
  </affiliate_zh>
  <abstract_zh>摘要: 对近5年来信息检索的相关研究按照语义资源的建设、检索结果自身特征、日志挖掘、用户
  </abstract_zh>
  <keywords_zh>关键词: 语义; 自身特征; 交互; 日志挖掘</keywords_zh>
  <keywords_en>Key words: Semantic; own characteristics; Interactive; Log Mining</keywords_en>
  <classified_code_zh>分类号: G350</classified_code_zh>
  <section1><subtitle_zh>1 引言</subtitle_zh>
  <paragraph>随着检索技术的发展, 从网络中获取信息已经成为科研、工作和学习中不可缺少的一部分, 用户越来
  </paragraph>
  </section1>
  <section2><subtitle_zh>2 基于语义的检索服务</subtitle_zh>
  <paragraph>基于语义资源建设的检索服务是在语义资源的基础上探索如何帮助用户改善检索效果以提升信息检索
  </paragraph>
  <paragraph>基于统计特征的检索服务是针对检索术语将检索结果集中所隐含的语义信息进行统计, 根据语义统计
  </paragraph>
  <paragraph>基于本体的检索服务技术主要是利用本体提供的语义信息, 可以是语义关系, 也可以是语义含义等,
  </paragraph>
  <paragraph>Textpresso是基于本体的生物学领域的信息检索和提取系统[ ], Textpresso基于已有的Gene Ontol
  </paragraph>
  <paragraph>IAToNews是基于自建本体的典型应用[ ], 是强大的本体和智能为基础的用户读取和网络浏览器:
  </paragraph>
  <paragraph>HealthFinland[ ]是既包含包含自建本体又包括已有本体的一个典型的应用, 是解决从出版商和公民
  </paragraph>
  <graph>图1 HealthFinland系统结构图[8]</graph>
  <paragraph>HealthFinland用基于共享本体的语义元数据标注本地内容, 并用基于语义的门户网站和集成web服务
  </paragraph>
  <graph>图2 HealthFinland检索界面图(允许用户查询用五个方面有关的查询关键词限制)[8]</graph>
  <paragraph>基于本体的检索服务按照本体资源的领域可分为专业本体和综合本体, 专业本体如Gene Ontology、I
  </paragraph>
  <graph>图3 GOMed 工作原理 [11]</graph>
  <graph>图4 GOMed检索界面</graph>
```

图4 文档结构框架示例

Figure 4 An example of document structure frame

同一自然段内的不同行的文本是分行的,因此需要对段落进行合并。开头为【数字+中/英文】且没有特殊标点符号、长度在一定范围之内内的文字行视为正文章节标题。开头为【图/表/Figure/ Table + 数字】且没有特殊标点符号、长度在一定范围之内内的文字行看作图、表标题。标题行都单独成自然段。【参考文献/References】开头的文字行为参考文献标题,单独成自然段,类似的还有【摘要/Abstract】【关键词/Keywords】【分类号/Classification】【致谢/Acknowledge】。如果中文论文的正文中的文字块的第一行是两个空格开头,则将其视为自然段的开始行,后面的行依次合并。如果英文论文正文中的文字块第一行以大写字母开头,且上一行用“.”等标点符号结束,则视为段落开始,后面的行依次合并。

经过文字块重排序和段落合并后,就得到了科技论文的较为整齐的全文内容。为了提取论文的结构框架元素,本文将第3节的结构框架元素分为文本元素和图表元素,分别进行提取。其中图表元素为论文中的图片内容和表格内容,以PNG格式存放。其余框架元素皆为文本元素。

#### 4.3 文本元素提取

在中文全文提取的基础上,将全文分割为段落。依次对每个段落进行判断。

论文首页的段落进行逐段判断。利用NER工具识别人名和机构名确定作者元素。根据“摘要/Abstract”“关键词/Keywords”“DOI”“分类号/Classification”“中图分类号”“文献标识码/文献标志码”“文章编号”“参考文献/Reference”等固定词语切分文字块,得到摘要,关键词,分类号,标识码,参考文献等元素。按照标题在作者上方的特点提取标题。正文采用关键词、分类号等位置的下一个段落进行提取。

如果符合【图+数字A】形式,此段落判为对图A的描述性文字,如果有好几个段落均为对A的描述,根据情况选择最长段落或者进行段落叠加。为了减少OCR错误,这里增加一些特殊规则来实施模糊匹配,如:“图”字,在OCR中容易识别为“田”、“圈”等,阿拉伯数字1容易识别为“l”、“I”。如果符合【表+数字B】形式,此段落判为对表B的描述性文字,如果有好几个段落均为对B的描述,可以根据情况选择最长段落或者进行段落叠加。针对中文表格的模糊匹配规则诸如:“表”字在OCR中容易识别为“农”等。

英文的图表描述类似于中文的图表描述。如果符合【Fig|fig|FIG|Figure|figure + 数字A】形式,此段落判为对图A的描述性文字,如果符合【TABLE|Table|Tab. + 数字B】形式,此段落判为对表B的描述性文字,段落叠加规则类似于中文的图表描述。英文图表的模糊匹配规则如:阿拉伯数字5容易识别为“S”、“s”,Table后有时候会接续罗马数字I、II、III、IV、V、VI、VII、VIII等。英文半角字容易识别成全角字,需要进行统一转化。

经过上述提取,可以得到科技论文的文本文档结构框架的文本元素。图4为文档结构框架示例,以XML格式进行存储。

#### 4.4 图表元素提取

图表元素的提取采用了规则结合深度学习的机制。规则方法充分利用了图表在科技论文中的位置信息和版式信息,深度学习方法则将图表识别看作目标检测问题,通过Faster-RCNN神经网络来进行识别,两个方法相辅相成,互为补充,以获取更为准确的提取效果。

对于每一页PDF,将其转化为图片,对其进行OCR识别获取到OCR信息。通过4.3小节的规则方法找到可能的图标题或表标题,然后进行图表识别。由于科技论文中的图通常在图标题的上方,其所在的栏基本和图标题所在的栏是一致的。所以用图标题所在的文字块坐标作为图片截取的下边界,通过该文字块的坐标计算文字块长度和宽度,找到一个比较符合的文字块作为图片截取的上边界。根据文本特点,利用文本块的长度、高度、文章页总宽度以及文字块中的文本行数,设定规则。例如文本宽度占文章页总宽度比例不能低于阈值等。

找到上、下边界后,根据上下边界所在文字块的坐标以及分栏情况确定左右边界。以双栏论文为例,分如下情况进行截取:①上下边界所在文字块都在右侧栏,图片按照右栏的左右边界截取。②上下边界所在文字块都在左侧栏,图片按照左栏的左右边界截取。③按照上边界在右侧顶部,左右边界为右侧栏左右边界进行截取。④按照左右边界为整页左右边界进行截取。⑤左右边界:下边界所在的那一侧的左右边界进行截取

表格的提取类似于图的提取规则,区别在于表格标题通常在表格上方。通过【表+数字+文字】的规则找到可能的表标题,用表标题所在的文字块坐标作为表格截取的上边界,通过利用文字块的坐标计算文字块长度和宽度,找到一个比较符合的文字块作为图片截取的下边界。找到上、下边界后,根据上下边界所在文字块的坐标以及分栏情况进行截取。

由于上述规则方法并不能覆盖所有的图表在论文中的现象,因此在规则方法提取不到图表而文本元素中有含有图描述和表描述的时候,借助深度学习方法来提取图表。

卷积神经网络(CNN)具有强大的特征提取能力,近年来被广泛用于计算机视觉领域的目标检测中,成为当前目标检测的主流方法。这里应用基于分类的卷积神经网络目标检测来提取PDF论文的图表。这类算法的典型代表是基于region proposal的Faster RCNN,见图5。Faster-RCNN模型引入RPN(Region Proposal Network)直接产生候选区域。RPN网络采用一个CNN模型接收整张图片并提取特征图,进而在特征图上采用一个N×N的滑动窗口,对于每个滑窗位置都映射一个低维度的特征,将特征分别送入两个全连接层,一个用于分类预测,另外一个用于回归。这两个全连接层是共享的。

对输入图像进行不同窗口大小的滑窗完成从左往右、从上到下的滑动,每次滑动时候对当前窗口执行分类器。如果

当前窗口得到较高的分类概率,则认为检测到了物体。




图5 Faster-RCNN模型

Figure 5 Faster-RCNN model

对每个不同窗口大小的滑窗都进行检测后,会得到不同窗口检测到的物体标记,这些窗口大小会存在重复较高的部分,最后采用非极大值抑制(Non-Maximum Suppression, NMS)的方法进行筛选。最终,经过NMS筛选后获得检测到的物体。图6-图9为图元素和表元素提取的实例,其中左侧分别为中文PDF和英文PDF的单页样例,右侧上部为提取到的图和表,分别以JPG文件形式保存,文件标题为图或者表的标题;右侧下部为图或者表的文字描述。

## 5 实验

为了验证本文方法的有效性,这里利用准确率来分别评价文本框架元素和图表框架元素的抽取效果。准确率的计算方式为针对该类别框架元素中正确提取数量占有所有提取

数量的百分比。

### 5.1 文本框架元素效果

随机抽取100篇科技论文作为实验样本,其中包括中文数字型PDF、中文扫描型PDF、英文数字型PDF、英文扫描型PDF各25篇。每篇中文PDF都包含了“论文正标题、作者、摘要、关键词、分类号、注释、正文、引文、图描述、表描述、图、表”等结构框架元素;每篇英文PDF都包含了“论文正标题、作者、摘要、关键词、正文、引文、图描述、表描述、图、表”等结构框架元素。对每篇PDF利用OCR获取产生带有文字块、文字行、字符坐标等信息的以XML/JSON等常见存储形式表示的OCR结果,在此基础上利用4.3小节的方法提取文本框架元素。系统环境为Ubuntu 18.04和Cuda 9.2 + Cudnn 7.6.5,采用Python 3.7和Anaconda 3。依赖库包括Pytorch 1.5.0、torchvision 0.6.0、cudatoolkit 9.2、mmcv 1.2.4、cython。人工对提取结果进行准确率评价,结果见表2。

从表1的结果可以看出,无论是中文论文还是英文论文,数字型PDF的抽取效果要好于扫描型PDF。对于框架元素来说,摘要、关键词、分类号、注释、引文、图描述和表描述等元素的效果要优于标题、作者和正文,这是因为前者这些元素有明确的标识词。整体而言,本文方法能够有效地提取论文PDF中的文本框架元素。

### 5.2 图表框架元素效果

图表框架元素的提取需要安装的检测工具为基于Pytorch的深度学习目标检测工具箱mmdetection。本文采用labelme图像标注工具来制作COCO训练数据集。标注类别为Table(表格)、Figure(配图)。提取论文PDF的每页将其转为图片,数据生成时将图片格式化填充为2048\*2048后,进行




图6 中文论文图元素提取样例

Figure 6 An example of figure elements extraction from Chinese paper




图7 中文论文表元素提取样例

Figure 7 An example of table elements extraction from Chinese paper




图8 英文论文图元素提取样例

Figure 8 An example of figure elements extraction from English paper

缩放得到 512\*512 的数据以便于训练。将标注得到的 json 文件转换为 coco 格式数据,得到训练集 2238 个、测试集 200 个。

Faster RCNN 的训练采用分布式训练,修改 CONFIG 配置文件(faster\_rcnn\_r101\_fpn\_1x\_coco.py),载入预训练模型(resnet101.pth),对网络进行训练。结果可视化时载入训练结果模型,将待检测图片压缩并输入网络得到检测坐标。将检测坐标还原,对图片进行截取保存。验证结果采用 IoU,

其全称为交并比(Intersection over Union),计算的是“预测的边框”和“真实的边框”的交集和并集的比值。在此这里预设 IOU>0.8 即视为可预测输出。在测试集上经检测输出结果几乎均已超阈值输出(0.99 或 1)为主,约占总测试结果的 96% 以上。

对于与 5.1 小节相同的论文数据集,采用 4.4 小节的方法提取其图表框架元素,测试结果见表 3 和表 4。表 3 为图元素的提取效果,可以看出规则方法基本达到了 79.47%~




图9 英文论文表元素提取样例

Figure 9 An example of table elements extraction from English paper

表2 结构框架文本元素抽取效果

Table 2 Extraction effect of structural frame text elements

| 中文数字型 PDF |         | 中文扫描型 PDF |        | 英文数字型 PDF |        | 英文扫描型 PDF |        |
|-----------|---------|-----------|--------|-----------|--------|-----------|--------|
| 结构框架元素    | 准确率     | 结构框架元素    | 准确率    | 结构框架元素    | 准确率    | 结构框架元素    | 准确率    |
| 正标题       | 68.00%  | 正标题       | 64.00% | 正标题       | 76.00% | 正标题       | 68.00% |
| 作者        | 88.00%  | 作者        | 76.00% | 作者        | 84.00% | 作者        | 68.00% |
| 摘要        | 96.00%  | 摘要        | 92.00% | 摘要        | 68.00% | 摘要        | 62.50% |
| 关键词       | 96.00%  | 关键词       | 96.00% | 关键词       | 72.00% | 关键词       | 62.50% |
| 分类号       | 100.00% | 分类号       | 68.00% | 分类号       | /      | 分类号       | /      |
| 注释        | 92.00%  | 注释        | 92.00% | 注释        | /      | 注释        | /      |
| 正文        | 92.00%  | 正文        | 90.00% | 正文        | 68.00% | 正文        | 60.00% |
| 引文        | 88.00%  | 引文        | 68.00% | 引文        | 88.00% | 引文        | 91.67% |
| 致谢        | /       | 致谢        | /      | 致谢        | 84.21% | 致谢        | 68.75% |
| 图描述       | 94.90%  | 图描述       | 95.36% | 图描述       | 98.72% | 图描述       | 96.84% |
| 表描述       | 95.45%  | 表描述       | 88.89% | 表描述       | 80.00% | 表描述       | 78.36% |

表3 结构框架图元素抽取效果

Table 3 Extraction effect of structural frame figure elements

| 中文数字型 PDF        |        | 中文扫描型 PDF        |        | 英文数字型 PDF        |        | 英文扫描型 PDF        |        |
|------------------|--------|------------------|--------|------------------|--------|------------------|--------|
| 方法               | 准确率    | 方法               | 准确率    | 方法               | 准确率    | 方法               | 准确率    |
| 规则方法             | 79.47% | 规则方法             | 77.37% | 规则方法             | 82.20% | 规则方法             | 91.49% |
| Faster-RCNN      | 93.38% | Faster-RCNN      | 96.35% | Faster-RCNN      | 98.42% | Faster-RCNN      | 94.04% |
| Rule-Faster-RCNN | 94.04% | Rule-Faster-RCNN | 96.35% | Rule-Faster-RCNN | 99.47% | Rule-Faster-RCNN | 96.60% |

表4 结构框架表元素抽取效果

Table 4 Extraction effect of structural frame table elements

| 中文数字型PDF         |        | 中文扫描型PDF         |        | 英文数字型PDF         |        | 英文扫描型PDF         |        |
|------------------|--------|------------------|--------|------------------|--------|------------------|--------|
| 方法               | 准确率    | 方法               | 准确率    | 方法               | 准确率    | 方法               | 准确率    |
| 规则方法             | 73.33% | 规则方法             | 79.55% | 规则方法             | 78.26% | 规则方法             | 70.00% |
| Faster-RCNN      | 84.44% | Faster-RCNN      | 95.40% | Faster-RCNN      | 89.13% | Faster-RCNN      | 86.67% |
| Rule-Faster-RCNN | 84.44% | Rule-Faster-RCNN | 97.73% | Rule-Faster-RCNN | 91.30% | Rule-Faster-RCNN | 96.67% |

91.49%的提取准确率,深度学习方法达到了93.38%~98.42%的准确率,采用Rule-Faster-RCNN(规则结合Faster-RCNN)方法,在中文数字型PDF、中文扫描型PDF、英文数字型PDF、英文扫描型PDF上,都获得了优于单纯使用规则方法或Faster-RCNN方法的效果。表4为表元素的提取效果,可以看出规则方法基本达到了70%~79.55%的提取准确率,Faster-RCNN方法达到了84.44%~98.42%的准确率,Rule-Faster-RCNN方法在四种PDF上也都获得了优于单纯使用规则方法或Faster-RCNN方法的效果。

6 结 语

本文提出基于Rule-Faster-RCNN的多语论文PDF文档结构框架元素的解析方法,在对多语科技论文PDF文档进行特征分析后将科技论文全文的结构框架元素分为文本元素和图表元素,采用规则辅以深度学习方法分别进行提取,其中规则方法利用论文行文版式特点识别文字框架元素和图表元素,深度学习方法将图表识别看作目标检测构建Faster-RCNN网络来补充规则方法的不足。经过实验验证,基于Rule-Faster-RCNN的多语论文PDF文档结构框架元素的解析方法成功地获取了科技论文的有效全文知识。

由于PDF的解析效果有限,论文格式五花八门,本研究还有很大提升空间。目前的文本元素仅采用了规则方法,后续可以尝试加入深度学习来辅助进行提取。表元素的提取虽然采用了神经网络方法,但是仅将表作为图片进行了提取,未能提取出表格内部的文本信息,后续研究可以针对表格内容设计更为深入的解析方案。

参考文献

1 ADOBE SYSTEMS. Pdf reference edition[Z]. Adobe Systems Inc, 2003.

2 于丰畅,陆伟.基于机器视觉的PDF学术文献结构识别[J].情报学报,2019,38(4):384-390.

3 李贵林,李建中,杨艳.用Plug-in实现对PDF文件的信息提取[J].计算机应用,2003,(2):110-112.

4 张秀秀,张立峰. PDF文件文本内容提取研究[J].科技情报开发与经济,2008,18(36):118-120.

5 刘华中.面向PDF文档的论文元数据提取方法研究[D].秦皇岛:燕山大学,2012.

6 中国建设银行股份有限公司.一种用于解析PDF文件中的图片的方法及装置[P].中国:CN 112069771 A,2020-12-11.

7 张建东,陈仕吉,徐小婷,等.基于词向量的PDF表格抽取研究[J].数据分析与知识发现,2021,5(8):34-44.

8 上海云扩信息科技有限公司.一种计算机程序提取PDF文档及图片中文字内容的方法[P].中国:CN 113177541 A,2021-07-27.

9 西安理工大学.一种解决PDF中复杂流程图的自动识别与解析方法[P].中国:CN 113343744 A,2021-09-03.

10 京东数字科技控股有限公司.一种PDF文件的信息抽取方法和装置[P].中国:CN 110334346 A,2019-10-15.

11 陈云榕,刘立柱,叶晗.PDF文档中JPEG图像的自动提取技术研究[J].信息工程大学学报,2007(2):213-216.

12 张伯.基于PDF文字流的表格识别技术的研究[D].北京:北京工业大学,2010.

13 焦娜.PDF文档中数学公式检测方法[D].石家庄:河北大学,2014.

14 中国人民大学.一种从PDF文档中抽取表格数据和篇章结构的方法[P].中国:CN201911017195 X,2020-02-07.

15 唐锐,邓建新,叶志兴,等.PDF文件的表格抽取研究综述[J].计算机应用与软件,2021,38(7):1-8.

16 司明.表格识别的研究[D].西安:西安科技大学,2009.

17 潘军.复杂表格文档预处理与文本提取算法研究[D].北京:北京交通大学,2017.

18 卞静潇.复杂版面文档图像表格与图的提取及分析[D].西安:西安电子科技大学,2015.

19 马志远,余粟.基于Faster-RCNN网络的表格检测算法研究[J].智能计算机与应用,2020,10(12):24-31.

20 中国建设银行股份有限公司.一种用于解析PDF文件中的图片的方法及装置[P].中国:CN 112069771 A, 2020-12-11.

21 京东数字科技控股有限公司.一种PDF文件的信息抽取方法和装置[P].中国:CN 110334346 A, 2019-10-15.

22 西安理工大学.一种解决PDF中复杂流程图的自动识别与解析方法[P].中国:CN 113343744 A, 2021-09-03.

23 Mao Song, Rosenfeld Azriel, Kanungo Tapas. Document structure analysis algorithms:a literature survey[J].Physica A: Statistical Mechanics and its Applications,2003(5010):197-

- 207.
- 24 王佳敏,陆伟,刘家伟,等.多层次融合的学术文本结构功能识别研究[J].图书情报工作,2019,63(13):94-103.
- 25 朱海军,张桂平,蔡东风,等.科技论文的标题识别[C]//第九届全国计算语言学学术会议,2007.
- 26 KIM J, LE D X, THOMA G R. Automated labeling in document images[C]//Proceedings of the SPIE conference on document recognition and retrieval VIII. San Jose:SPIE, 2000:111-122.
- 27 CONSTANTIN A, PETTIFER S, VORONKOV A. PDFX: fully automated PDF-to-XML conversion of scientific literature[C]//Proceedings of the ACM symposium on document engineering. Florence: ACM, 2013:177-180.
- 28 LUONG M T, NGUYEN T D, KAN M Y. Logical structure recovery in scholarly articles with rich document features [J]. International journal of digital library systems, 2010, 1(4):1-23.
- 29 TUAROB S, MITRA P, GILES C L. A hybrid approach to discover semantic hierarchical sections in scholarly documents[C]//Proceedings of the 13th international conference on document analysis and recognition. Mancy: IAPR, 2015:1081-1085.
- 30 陆伟,黄永,程齐凯.学术文本的结构功能识别—功能框架及基于章节标题的识别[J].情报学报,2014,33(9):979-985.
- 31 黄永,陆伟,程齐凯.学术文本的结构功能识别—基于章节内容的识别[J].情报学报,2016,35(3):293-300.
- 32 黄永,陆伟,程齐凯,等.学术文本的结构功能识别—基于段落的识别[J].情报学报,2016,35(5):530-538.
- 33 R AHMAN M M, FININ T. Deep understanding of a document's structure[C]//Proceedings of the 3rd IEEE/ACM international conference on Big Data computing, applications and technologies. 2017:63-73.
- 34 刘忠宝,王宇飞,赵文娟.基于章节段落的学术文献结构功能识别方法研究[J].文献与数据学报,2020,2(3):37-47.

(责任编辑:孙晓明)

## Extraction of Structure Frame Elements of PDF Documents in Multilingual Scientific Papers Based on Rule-Faster-RCNN

HE Yan-qing<sup>1</sup>, CHEN Guang-yun<sup>2</sup>, LAN Tian<sup>1</sup>, LI Yan<sup>1</sup>, GUO Hang-cheng<sup>1</sup>

(1. Research Center of Information Theory and Method, Institute of Scientific and Technical Information of China, Beijing 100038, China; 2. Research Center, Yunnan Tin Group (holding) Company Limited, Kunming 650000, China)

**Abstract:** [Purpose/significance] PDF documents can faithfully preserve the content and appearance of the original document, but it brings great difficulties to the parsing of the document. In order to mine multilingual scientific and technological texts more comprehensively and automatically, the methods of effective parsing and knowledge extraction for PDF documents of multilingual scientific papers are explored. [Method/process] This paper proposes a Rule-Faster-RCNN-based method for the structural frame elements of multilingual scientific papers in PDF file format. The structural frame elements of papers' full text are divided into text elements and graph-table elements, and the rules are combined with deep learning methods to extract them respectively. The rule method uses the characteristics of the paper layout to identify the text frame elements and graph-table elements, the deep learning method regards graph-table recognition as target detection and constructs a Faster-RCNN network to supplement the deficiencies of the rule method. [Result/conclusion] Experiments show that the PDF parsing method proposed in this paper is superior to the baseline method, and the full-text knowledge of scientific papers is successfully obtained effectively. [Innovation/limitation] The rules and deep learning methods are used to extract the structural framework elements of the full-text documents of multilingual scientific papers more precisely, and the effectiveness of the method is verified by experiments; however, due to the complexity of PDF documents, the table elements are only extracted as pictures, and the text information inside the table cannot be mined.

**Keywords:** multilingual scientific papers; PDF documents; structural frame elements; graph-table analysis; rule-faster-RCNN